

統計検定2級 暗記メモ

1. 確率変数の基本（離散 vs 連続）

離散型確率変数 (Discrete)

サイコロの目やコインの枚数のように「とびとびの値」をとるもの。

- 期待値: $E[X] = \sum_k x_k p_k$
- 分散: $V[X] = \sum_k (x_k - \mu)^2 p_k = E[X^2] - (E[X])^2$

連続型確率変数 (Continuous)

身長や時間のように「連続した値」をとるもの。

- 期待値: $E[X] = \int_{-\infty}^{\infty} x f(x) dx$
- 分散: $V[X] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx = E[X^2] - (E[X])^2$

★重要公式：確率変数の演算

定数 a, b および 独立な確率変数 X, Y について：

- 期待値: $E[aX + b] = aE[X] + b$
- 期待値の和: $E[X + Y] = E[X] + E[Y]$ （独立でなくても成立）
- 分散: $V[aX + b] = a^2 V[X]$ （定数 b は消える）

- 分散の和・差: $V[X \pm Y] = V[X] + V[Y]$
 - 注意: 独立なら、差 ($X - Y$) でも分散は足し算になる。

2. 離散型分布 (Discrete)

離散一様分布 (Discrete Uniform)

- 記号: $U(N)$ (一般的に 1 から N までの整数をとる場合)
- 概要: すべての値が出る確率が等しい分布。(例: 公正なサイコロは $N = 6$ の離散一様分布)
- 確率: $P(X = k) = \frac{1}{N}$
- 期待値: $E[X] = \frac{N+1}{2}$ (例: サイコロの平均は 3.5)
- 分散: $V[X] = \frac{N^2-1}{12}$ (※連続一様分布の分散 $\frac{(b-a)^2}{12}$ と似ているが、こちらは -1 が入る点に注意)

ベルヌーイ分布 (Bernoulli)

- 概要: 1回だけ試行して、成功(1)か失敗(0)か。全ての基本。
- 期待値: $E[X] = p$
- 分散: $V[X] = p(1 - p)$

二項分布 (Binomial)

- 記号: $B(n, p)$
- 概要: n 回試行して、成功する回数。
- 確率: $P(X = k) = {}_nC_k p^k (1 - p)^{n-k}$
- 期待値: $E[X] = np$
- 分散: $V[X] = np(1 - p)$

ポアソン分布 (Poisson)

- 記号: $Po(\lambda)$
- 概要: 「稀な事象」が一定期間に起きる回数。(例: 1時間の来客数、事故件数)
 - 二項分布で n が大、 p が小の極限。 $\lambda = np$
- 確率: $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$
- 期待値: $E[X] = \lambda$
- 分散: $V[X] = \lambda$
- 再生性: $X \sim Po(\lambda_1), Y \sim Po(\lambda_2)$ (独立) $\Rightarrow X + Y \sim Po(\lambda_1 + \lambda_2)$

幾何分布 (Geometric)

- 概要: 初めて成功するまでに「試行」した回数。(※失敗回数 $k - 1$ を問う定義もあるため問題文注意)
- 確率: $P(X = k) = p(1 - p)^{k-1}$
- 期待値: $E[X] = \frac{1}{p}$
- 分散: $V[X] = \frac{1-p}{p^2}$

負の二項分布 (Negative Binomial)

- 概要: 成功回数が r 回になるまでに行う「試行」の回数。幾何分布を r 回繰り返す (それぞれは独立)。 $r = 1$ のとき幾何分布になる。
- 確率: $P(X = k) = {}_{k-1}C_{r-1} p^r (1 - p)^{k-r} \quad (k \geq r)$
(解説: 最後の k 回目に r 回目の成功が来る。それ以前の $k - 1$ 回の中で $r - 1$ 回成功している必要があるため、組み合わせ C がつく)
- 期待値: $E[X] = \frac{r}{p}$
- 分散: $V[X] = \frac{r(1-p)}{p^2}$

超幾何分布 (Hypergeometric)

- 概要: 「非復元抽出」。当たり M 個・ハズレ $N - M$ 個の壺から n 個取り出した時の当たりの数。

。母集団が非常に大きい場合は「二項分布」で近似できるため、近似計算させる問題が多い。

- 期待値: $E[X] = n \frac{M}{N}$ (直感的: $n \times$ 当たり率)
- 分散: $V[X] = n \frac{M}{N} \left(1 - \frac{M}{N}\right) \left(\frac{N-M}{N-1}\right)$

3. 連続型分布 (Continuous)

一様分布 (Uniform)

- 記号: $U(a, b)$
- 概要: 区間 $[a, b]$ で確率が一定 (長方形)。
- 確率密度: $f(x) = \frac{1}{b-a}$
- 期待値: $E[X] = \frac{a+b}{2}$ (ど真ん中)
- 分散: $V[X] = \frac{(b-a)^2}{12}$ (※分母の12は暗記推奨)

正規分布 (Normal)

- 記号: $N(\mu, \sigma^2)$
- 概要: 最重要分布。左右対称。
- 期待値: $E[X] = \mu$
- 分散: $V[X] = \sigma^2$
- 再生性: 正規分布同士の和も正規分布になる。
 - $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ (独立) なら、
 - $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
- 標準化: $z = \frac{X-\mu}{\sigma}$ の値で標準正規分布表を読む
- 偏差値: $50 + 10 \times \frac{X-\mu}{\sigma}$

- **中心極限定理** 標本増⇒期待値: μ 分散: $\frac{\sigma^2}{n}$ の正規分布 $N\left(\mu, \frac{\sigma^2}{n}\right)$ に近づく
- **予言区間:** $\bar{X} \pm t_{\frac{\alpha}{2}}(n-1) \times s \sqrt{1 + \frac{1}{n}}$ (データ1つの予測範囲)

指数分布 (Exponential)

- **記号:** $Ex(\lambda)$
- **概要:** ランダムな事象が発生するまでの「間隔 (時間)」。ポアソン分布の親戚。
 - 「無記憶性」を持つ (これまでの経過時間は、今後の発生確率に影響しない)。
- **確率密度:** $f(x) = \lambda e^{-\lambda x} \quad (x \geq 0)$
- **期待値:** $E[X] = \frac{1}{\lambda}$
- **分散:** $V[X] = \frac{1}{\lambda^2}$

4. 2変数の関係・回帰分析

共分散と相関係数

- **共分散:** $S_{xy} = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y}) = E[XY] - E[X]E[Y]$ (偏差の積の平均)
- **相関係数 (r):** $r = \frac{S_{xy}}{S_x S_y}$ (共分散を標準偏差の積で割る)

単回帰分析

- **モデル:** $y = a + bx + \epsilon$
- **回帰係数 (傾き):** $\hat{b} = \frac{S_{xy}}{S_x^2} = r \frac{S_y}{S_x}$
(※相関係数に標準偏差の比をかけたもの)
- **決定係数:** $R^2 = (\text{相関係数 } r)^2$ (回帰の当てはまりの良さ、単回帰の場合のみ成立)

5. 推定・検定の三大分布

標本統計量

- 標本平均 (= 推定量) : $\bar{X} = \sum_{i=1}^n x_i$
- 標本分散: $S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
- 不偏分散 (= 推定量) : $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
- 標準誤差 (標本平均の標準偏差の平均) : $\frac{s}{\sqrt{n}}$

カイ二乗分布 (χ^2 分布)

一言で: 標準正規分布の「2乗の和」。分散のための分布。

- 1. 定義 (構成式)

標準正規分布 $N(0, 1)$ に従う独立な確率変数 $Z_1, \dots, Z_n$ の「2乗の和」。

$$W = \sum_{i=1}^n Z_i^2 = Z_1^2 + \dots + Z_n^2$$

これは、自由度 n のカイ二乗分布 $\chi^2(n)$ に従う。

- 2. 統計量

自由度を n とすると：

- 期待値: $E[W] = n$ (自由度はそのまま平均になる)
- 分散: $V[W] = 2n$ (平均の2倍)

- 3. グラフの形状・性質

- 左右非対称: 左に山があり、右に裾が長く伸びる ($x \geq 0$)。

- **正規近似:** 自由度 n が大きくなると、正規分布に近づく。
- **再生性:** $\chi^2(m)$ と $\chi^2(n)$ が独立なら、足すと $\chi^2(m+n)$ になる。
- **4. 主な用途**
 - **母分散の推定・検定:** 母平均が未知の場合の分散の検証。
 - **適合度検定:** 理論値と観測値のズレの検証。
 - **独立性検定:** クロス集計表での属性間の関連の検証。

t分布 (Student's t)

一言で: 母分散が未知のときに、正規分布の代役を務める分布。

- **1. 定義（構成式）**

$Z \sim N(0, 1)$ と $W \sim \chi^2(n)$ が独立であるとき、

$$t = \frac{Z}{\sqrt{W/n}}$$

これは、自由度 n のt分布 $t(n)$ に従う。

(イメージ: $\frac{\text{標準正規分布}}{\sqrt{\text{カイ二乗/自由度}}}$)

- **2. 統計量**

- **期待値:** 0 ($n > 1$ のとき。正規分布と同じく真ん中)
- **分散:** $\frac{n}{n-2}$ ($n > 2$ のとき。1より少し大きいのが特徴)

- **3. グラフの形状・性質**

- **左右対称:** 正規分布と同じ釣り鐘型。
- **裾が厚い (Heavy tail):** 正規分布より頂上が低く、端っこの確率が高い（外れ値が出やすい）。
- **収束:** 自由度 $n \rightarrow \infty$ で標準正規分布 $N(0, 1)$ に一致する。

- **4. 主な用途**

- **母平均の推定・検定:** 母分散 σ^2 が分からないとき（不偏分散 u^2 で代用するとき）に使う。

F分布

一言で: 「分散の比」。2つのばらつきを比較するための分布。

- 1. 定義（構成式）★暗記

$W_1 \sim \chi^2(n_1)$ と $W_2 \sim \chi^2(n_2)$ が独立であるとき、

$$F = \frac{W_1/n_1}{W_2/n_2}$$

これは、自由度 (n_1, n_2) のF分布 $F(n_1, n_2)$ に従う。(イメージ: $\frac{\text{カイ二乗/自由度}}{\text{カイ二乗/自由度}}$)

- 2. 統計量

- 複雑なので暗記不要（期待値は1付近になる）。

- 3. 重要な性質 ★暗記

分布表を引くために以下の式変形が必須となる。

- i. 逆数の関係: $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$

（下側 α の点を知りたいときは、自由度を入れ替えて逆数をとる）

- ii. t分布との関係: $t(n)^2 = F(1, n)$

（t分布の2乗は、分子の自由度が1のF分布と等しい）

- 4. 主な用途

- 等分散性の検定: 2つの集団の分散が等しいかチェックする（F検定）。
- 分散分析 (ANOVA): 3つ以上のグループの平均値に差があるか調べる。

6. 推定と検定

表のポイントと補足

- **不偏分散 s^2 :** 標本分散 ($1/n$) ではなく、不偏分散 ($1/(n - 1)$) を用いる点に注意。
- $z_{\alpha/2}$: 標準正規分布の上側確率 $\alpha/2$ となる点 (95%信頼区間なら 1.96)。
- **母分散の信頼区間:** χ^2 分布は左右対称ではないため、下限と上限で分母の χ^2 値が異なります。

1標本

※信頼区間は $1 - \alpha$ 、検定は両側検定 (有意水準 α) とする。

ケース (条件)	使用する分布	推定：信頼区間 (中心 ± 幅)	検定：検定統計量 (ズレを測る式)	重要ポイント
母平均 (分散既知 or n 大)	標準正規 $N(0, 1)$	$\bar{X} \pm z_{\frac{\alpha}{2}} \times \sqrt{\frac{\sigma^2}{n}}$	$Z = \frac{\bar{X} - \mu_0}{\sqrt{\sigma^2/n}}$	分母 (標準誤差) は共通。 σ が未知で n が大なら s で代用。
母平均 (分散未知・ n 小)	t 分布 $t(n - 1)$	$\bar{X} \pm t_{\frac{\alpha}{2}} \times \sqrt{\frac{s^2}{n}}$	$t = \frac{\bar{X} - \mu_0}{\sqrt{s^2/n}}$	分散に不偏分散 s^2 を使う。 係数が z ではなく t になる。
母比率 (n 大)	標準正規 $N(0, 1)$	$\hat{p} \pm z_{\frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	最大の違い 推定：標本比率 $\hat{p}$ を使う 検定：仮説値 p_0 を使う
母分散 (正規母集団)	χ^2 分布 $\chi^2(n - 1)$	$\frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}} < \sigma^2 < \frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}}$	$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$	分子は共通。 検定は分母に仮説値 σ_0^2 が入る。

2標本（対応無し）

※帰無仮説は「差がない（ $\mu_1 = \mu_2, p_1 = p_2$ ）」、有意水準 α とする。

ケース（条件）	使用する分布	推定：信頼区間 （差 ± 幅）	検定：検定統計量 （差 / 標準誤差）	重要ポイント
母平均の差 （分散既知 or n 大）	標準正規 $N(0, 1)$	$(\bar{X}_1 - \bar{X}_2) \pm z_{\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	それぞれの分散を足してルート。 検定統計量の分子は、帰無仮説 $\mu_1 - \mu_2 = 0$ より単純化される。
母平均の差 （分散未知・ 等分散）	t 分布 $t(n_1 + n_2 - 2)$	$(\bar{X}_1 - \bar{X}_2) \pm t_{\frac{\alpha}{2}} \times \sqrt{s^2(\frac{1}{n_1} + \frac{1}{n_2})}$	$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{s^2(\frac{1}{n_1} + \frac{1}{n_2})}}$	プールした分散 s^2 を使う 自由度 $\nu = n_1 + n_2 - 2$ $s^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$
母比率の差 （ n 大）	標準正規 $N(0, 1)$	$(\hat{p}_1 - \hat{p}_2) \pm z_{\frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$	$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})(\frac{1}{n_1} + \frac{1}{n_2})}}$	最大の違い 推定：個別の $\hat{p}_1, \hat{p}_2$ を使う 検定：統合した $\hat{p}$ を使う $\hat{p} = \frac{x_1+x_2}{n_1+n_2}$
母分散の比 （正規母集団）	F 分布 $F(n_1 - 1, n_2 - 1)$	$\frac{s_1^2}{s_2^2} \frac{1}{F_{\frac{\alpha}{2}}} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{s_1^2}{s_2^2} \frac{1}{F_{1-\frac{\alpha}{2}}}$	$F = \frac{s_1^2}{s_2^2}$	自由度は $(n_1 - 1, n_2 - 1)$ 。 検定は「大きい方/小さい方」で計算し、 片側検定表を応用することが多い。

7. その他 重要暗記項目

第1種の過誤と第2種の過誤

	H_0 が真（差がない）	H_1 が真（差がある）
棄却する (差ありとする)	第1種の過誤 (α) 生産者危険（誤検知）	正しい判定 (検出力 $1 - \beta$)
採択する (差なしとする)	正しい判定	第2種の過誤 (β) 消費者危険（見逃し）

独立性の検定（カイ二乗検定）

クロス集計表の行要素と列要素に関連があるか。

- 期待度数: $E_{ij} = \text{列合計} \times \frac{\text{行合計}}{\text{総計}}$ ※列合計に行比率を乗算する（行列の入れ替え可）
- 統計量: $\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \sum \frac{(\text{観測} - \text{期待})^2}{\text{期待}}$
- 自由度: $(\text{行数} - 1) \times (\text{列数} - 1)$

一元配置分散分析表

- a : 水準数（グループ数）
- n : データ総数

要因 (Source)	平方和 (S) 【ズレの総量】	自由度 (df) 【情報の数】	平均平方 (V) 【分散】	F 値 【S/N比】
要因 (群間) Effect	S_A $\sum n_i(\bar{x}_i - \bar{\bar{x}})^2$ ※各群平均と全体平均の差	$a - 1$ (群数 - 1)	$V_A = \frac{S_A}{df_A}$	$F = \frac{V_A}{V_E}$
残差 (群内) Error	$S_E = S_T - S_A$ ※ここを直接計算するのは禁止。 必ず (全体 - 要因) で出す！	$n - a$ (総数 - 群数) ※ $(n - 1) - (a - 1)$	$V_E = \frac{S_E}{df_E}$	
全体 Total	S_T $\sum (x_{ij} - \bar{\bar{x}})^2$ ※全データの通常の分散 $\times (n - 1)$	$n - 1$ (データ総数 - 1)		

解法のアプローチ

- 自由度(df)を全部埋める（単なる引き算）。
- 全体(S_T)と要因(S_A)を計算する。
- 残差(S_E)は引き算($S_T - S_A$)で求める（加法性を利用）。

二元配置分散分析表（繰り返しあり）

- a : Aの水準数
- b : Bの水準数
- n : 各水準ごとのデータ数（繰り返し回数）
- N : 全データ総数 ($a \times b \times n$)

要因 (Source)	平方和 (S)	自由度 (df) 【掛け算で出せる】	平均平方 (V)	F 値
要因A	S_A	$a - 1$	$V_A = S_A/df_A$	V_A/V_E
要因B	S_B	$b - 1$	$V_B = S_B/df_B$	V_B/V_E
交互作用 ($A \times B$)	$S_{A \times B}$ ※引き算で出すのが安全 ($S_{\text{群間}} - S_A - S_B$)	$(a - 1)(b - 1)$ ※AとBの自由度の掛け算	$V_{A \times B} = \frac{S_{A \times B}}{df_{A \times B}}$	$\frac{V_{A \times B}}{V_E}$
残差 (Error)	S_E ※全体から上記3つを引く	$ab(n - 1)$ ※全体 - 他の自由度の和	$V_E = S_E/df_E$	
全体	S_T	$abn - 1$ (全データ数 - 1)		

解法アルゴリズム（引き算の極意）

1. **自由度を埋める**: 交互作用の df は $(a - 1) \times (b - 1)$ なので計算不要。
2. **$S_{\text{群間}}$ (Subtotal) を意識する**: 「A×Bの各マス（セル）」の平均を使った分散のこと。
 - $S_{A \times B} = S_{\text{群間}} - S_A - S_B$
 - つまり、「セルのバラつき」から「A単体の効果」と「B単体の効果」を引いた残りが「相性（交互作用）」になる。
3. **S_E (残差) を出す**: S_T (全体) - $S_{\text{群間}}$ で求められる。