

統計検定準1級：統合メモ

確率

- ベイズの定理: $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ 、事後確率 = $\frac{\text{尤度} \times \text{事前確率}}{\text{周辺尤度}}$

基本統計

- 期待値 (離散型) : $E[X] = \sum_x xp(x)$
- 期待値 (連続型) : $E[X] = \int_{-\infty}^{\infty} xf(x)dx$
- 分散 (離散型) : $V[X] = E[X^2] - (E[X])^2 = \sum_x (x - \mu)^2 p(x)$
- 分散 (連続型) : $V[X] = E[X^2] - (E[X])^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x)dx = \int_{-\infty}^{\infty} x^2 f(x)dx - \left(\int_{-\infty}^{\infty} xf(x)dx\right)^2$
- 共分散: $Cov[X, Y] = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$
- 相関係数: $\rho[X, Y] = E\left[\left(\frac{X - E[X]}{\sqrt{V[X]}}\right)\left(\frac{Y - E[Y]}{\sqrt{V[Y]}}\right)\right] = \frac{Cov[X, Y]}{\sqrt{V[X]V[Y]}}$
- 偏相関係数: $\rho[X, Y|Z] = \frac{\rho[X, Y] - \rho[X, Z]\rho[Y, Z]}{\sqrt{(1 - \rho[X, Z]^2)(1 - \rho[Y, Z]^2)}}$
- 標準偏差: $SD = \sigma = \sqrt{V[X]}$
- 変動係数: $CV = \frac{\sqrt{V[X]}}{E[X]}$
- 確率密度関数: $\int_{-\infty}^{\infty} f(x)dx = 1$
- 累積分布関数: $F(x) = \int_{-\infty}^x f(t)dt$
- 生存関数: $S(x) = 1 - F(x)$
- ハザード関数: $h(x) = \frac{f(x)}{1 - F(x)} = \frac{f(x)}{S(x)} = (-\log S(x))'$
- 確率母関数: $G(s) = E[s^X] = \sum_x s^x p(x)$
 - $G'(s) = E[Xs^{X-1}]$ 、 $G''(s) = E[X(X-1)s^{X-2}]$
 - $G'(1) = E[X]$ 、 $G''(1) = E[X(X-1)] \iff E[X^2] = G''(1) + G'(1)$
 $\Rightarrow E[X] = G'(1)$ 、 $V[X] = E[X^2] - (E[X])^2 = G''(1) + G'(1) - (G'(1))^2$
 - $G^{(k)}(0) = k!P(X = k) \iff P(X = k) = \frac{G^{(k)}(0)}{k!}$ (確率母関数から確率を復元)
- モーメント母関数: $m(t) = G(e^t) = E[e^{tX}]$
 - $m'(t) = E[Xe^{tX}]$ 、 $m''(t) = E[X^2e^{tX}]$
 - $m'(0) = E[X]$ 、 $m''(0) = E[X^2]$ 、 $m^{(k)}(0) = E[X^k]$
 - $E[X] = m'(0)$ 、 $V[X] = E[X^2] - (E[X])^2 = m''(0) - (m'(0))^2$
 - 独立な X_1 、 X_2 の和のモーメント母関数: $m(t) = m_1(t)m_2(t) \Rightarrow m_n(t) = m(t)^n$
- 歪度: $S[X] = \frac{E[X - E[X]]^3}{\sigma^3}$
 - $S[X] = \frac{E[X]^3}{\sigma^3} = \frac{m'''(0)}{m''(0)^{3/2}} \quad s.t. E[X] = 0$

- 尖度: $K[X] = \frac{E[X-E[X]]^4}{\sigma^4}$
 - $K[X] = \frac{E[X]^4}{\sigma^4} = \frac{m'''(0)}{m''(0)^2}$ $s.t. E[X] = 0$ 正規分布の場合は3

条件付き期待値/分散、全期待値/分散

- 条件付き確率 (密度): $f(y|x) = \frac{f(x,y)}{f_X(x)}$
- 条件付き期待値: $E[Y|X=x] = \int_{-\infty}^{\infty} y f(y|x) dy$ (※ x の関数になる)
- 全期待値の定理: $E[Y] = E_X[E[Y|X]]$
- 全分散の公式: $V[Y] = E_X[V_{Y|X}[Y|X]] + V_X[E_{Y|X}[Y|X]]$

平均

- 算術平均 (相加平均): $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- 加重平均 (重み付き平均): $\bar{x}_w = \sum_{i=1}^n w_i x_i$
- 幾何平均 (相乗平均): $\bar{x}_g = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}} = \sqrt[n]{x_1 x_2 \cdots x_n}$
- 調和平均 (割合平均): $\bar{x}_h = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} = \left(\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i} \right)^{-1}$ (逆数の平均の逆数)
- 各種平均の大小関係: 調和平均 $\leq$ 幾何平均 $\leq$ 算術平均
 - 正の値の場合、等号成立は全データが等しい場合

変数変換

- 1変数の変数変換: $f_Y(y) = f_X(g^{-1}(y)) \left| \frac{dx}{dy} \right| = f_X(x) \left| \frac{dx}{dy} \right|$
- 2変数の変数変換: $f_{U,V}(u,v) = f_{X,Y}(x(u,v), y(u,v)) |J|$
- ヤコビアン: $J = \frac{\partial(x,y)}{\partial(u,v)} = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix} = \frac{\partial x}{\partial u} \frac{\partial y}{\partial v} - \frac{\partial x}{\partial v} \frac{\partial y}{\partial u}$
- 対数変換: $y = \log(x)$
- べき乗変換: $y = x^\lambda$ $\lambda = 0.5$ (平方根変換、ポアソン分布の分散安定用)、 -1 (逆数変換)
- Box-Cox変換: $y^{(\lambda)} = \begin{cases} \frac{x^\lambda - 1}{\lambda} & (\lambda \neq 0) \\ \log(x) & (\lambda = 0) \end{cases}$
- ロジット変換 (対数オッズ): $y = \log \left(\frac{p}{1-p} \right)$
 - ロジスティック回帰分析のリンク関数、逆変換でロジスティック関数 (シグモイド関数)
- プロビット変換: $y = \Phi^{-1}(p)$ (Φ^{-1} は標準正規分布の累積分布関数の逆関数)
 - 確率 p を標準正規分布の z 値に変換

離散型分布

分布名	確率質量関数 (PMF)	期待値 $E[X]$	分散 $V[X]$	モーメント母関数 $M(t)$
離散一様分布 $DU(N)$	$\frac{1}{N}$	$\frac{N+1}{2}$	$\frac{N^2-1}{12}$	$\frac{e^t(1-e^{Nt})}{N(1-e^t)}$
ベルヌーイ分布 $B(p), Bin(1, p)$	$p^x(1-p)^{1-x}$	p	$p(1-p)$	$pe^t + 1 - p$
二項分布 $Bin(n, p)$	${}_nC_x p^x (1-p)^{n-x}$	np	$np(1-p)$	$(pe^t + 1 - p)^n$
超幾何分布 $HG(N, M, n)$	$\frac{{}_M C_x \cdot {}_{N-M} C_{n-x}}{{}_N C_n}$	$n \frac{M}{N}$	$n \frac{M}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1}$	(省略)
ポアソン分布 $Po(\lambda)$	$\frac{\lambda^x e^{-\lambda}}{x!}$	λ	λ	$e^{\lambda(e^t-1)}$
幾何分布 $Geo(p)$ ※失敗回数 x	$p(1-p)^x$	$\frac{1-p}{p}$	$\frac{1-p}{p^2}$	$\frac{p}{1-(1-p)e^t}$
負の二項分布 $NB(r, p)$ ※失敗回数 y	${}_y C_{r-1} p^r (1-p)^y$	$\frac{r(1-p)}{p}$	$\frac{r(1-p)}{p^2}$	$\left(\frac{p}{1-(1-p)e^t}\right)^r$

- **多項分布:** 二項分布を多次元に拡張した分布
 - 期待値: $E[X_i] = np_i$
 - 分散: $V[X_i] = np_i(1-p_i)$
 - 共分散: $Cov(X_i, X_j) = -np_i p_j \quad s.t. \ i \neq j$ (※変数が独立でないため負の相関)
- **再生性:**
 - 二項分布: $X_1 \sim Bin(n_1, p), X_2 \sim Bin(n_2, p) \Rightarrow X_1 + X_2 \sim Bin(n_1 + n_2, p)$
 - ポアソン分布: $X_1 \sim Po(\lambda_1), X_2 \sim Po(\lambda_2) \Rightarrow X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)$
 - 負の二項分布: $X_1 \sim NB(r_1, p), X_2 \sim NB(r_2, p) \Rightarrow X_1 + X_2 \sim NB(r_1 + r_2, p)$
 - 多項分布: (省略)
- **無記憶性:**
 - 幾何分布: $X \sim Geo(p) \Rightarrow P(X \geq t_1 + t_2 | X \geq t_2) = P(X \geq t_2)$
- **用途:**
 - 超幾何分布: フィッシャーの正確検定

連続型分布

分布名	確率密度関数 (PDF)	期待値 $E[X]$	分散 $V[X]$	モーメント母関数 $M(t)$
連続一様分布 $U(a, b)$	$\frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{bt}-e^{at}}{(b-a)t}$
正規分布 $N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	μ	σ^2	$\exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$
標準正規分布 $N(0, 1)$	$\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$	0	1	$\exp\left(\frac{t^2}{2}\right)$
対数正規分布 $\Lambda(\mu, \sigma^2)$ ※ $\log X \sim N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma x} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right)$	$\exp\left(\mu + \frac{\sigma^2}{2}\right)$	$\exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1)$	(存在しない)
指数分布 $Exp(\lambda)$	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\left(1 - \frac{1}{\lambda}t\right)^{-1}$
ガンマ分布 $Ga(a, b)$	$\frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}}$	ab	ab^2	$(1 - bt)^{-a}$
ベータ分布 $Be(a, b)$	$\frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1}$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$	(省略)
カイ二乗分布 $\chi^2(n)$	$Ga\left(\frac{n}{2}, 2\right)$	n	$2n$	$(1 - 2t)^{-\frac{n}{2}}$
t分布 $t(n)$	(暗記不要)	0 ($n > 1$)	$\frac{n}{n-2}$ ($n > 2$)	(存在しない)
F分布 $F(n_1, n_2)$	(暗記不要)	$\frac{n_2}{n_2-2}$ ($n_2 > 2$)	(暗記不要)	(存在しない)

• 多変量正規分布:

- 条件付き期待値 (2変量) : $E[Y|X = x] = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X)$
- 条件付き分散 (2変量) : $V[Y|X = x] = \sigma_Y^2(1 - \rho^2)$
- モーメント母関数: $M(\mathbf{t}) = E[e^{\mathbf{t}^\top \mathbf{X}}] = \exp\left(\boldsymbol{\mu}^\top \mathbf{t} + \frac{1}{2} \mathbf{t}^\top \Sigma \mathbf{t}\right)$
- 無相関と独立: 多変量正規分布に従う場合に限り、「無相関 (共分散が0)」と「独立」は同値
- 条件付き期待値 (多変量) : $\boldsymbol{\mu}_{1|2} = \boldsymbol{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2)$
- 線形変換: $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ 、 $\mathbf{Y} = A\mathbf{X} + \mathbf{b}$ の分布 $\Rightarrow \mathbf{Y} \sim N_q(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^\top)$

- **カイ二乗分布への接続:** 指数部分 $(\mathbf{X} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu})$ 変数 $\mathbf{X}$ と平均 $\boldsymbol{\mu}$ の間の「マハラノビス距離の2乗」
 - $\mathbf{X}$ が p 変量正規分布に従うとき、この二次形式は自由度 p のカイ二乗分布 $\chi^2(p)$ に従う
- **混合正規分布:**
 - **確率密度関数:** $f(x) = p_1 f_1(x) + \cdots + p_K f_K(x)$ 混合比率 p で正規分布を混ぜた分布
 - **累積分布関数:** $F(x) = p_1 F_1(x) + \cdots + p_K F_K(x)$
 - **期待値:** $E[X] = \sum_{k=1}^K p_k \mu_k$
 - **分散:** $V[X] = \sum_{k=1}^K p_k \sigma_k^2$ 群内分散 + 群間分散
 - **二峰性条件:** $p_1 = p_2 = 0.5, \sigma_1 = \sigma_2 = \sigma \Rightarrow |\mu_1 - \mu_2| > 2\sigma$
- **再生性:**
 - **正規分布:** $X_1 \sim N(\mu_1, \sigma_1^2), X_2 \sim N(\mu_2, \sigma_2^2) \Rightarrow X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
 - **ガンマ分布:** $X_1 \sim Ga(a_1, b), X_2 \sim Ga(a_2, b) \Rightarrow X_1 + X_2 \sim Ga(a_1 + a_2, b)$
 - **カイ二乗分布:** $X_1 \sim \chi^2(n_1), X_2 \sim \chi^2(n_2) \Rightarrow X_1 + X_2 \sim \chi^2(n_1 + n_2)$
- **無記憶性:**
 - **指数分布:** $X \sim Exp(\lambda) \Rightarrow P(X \geq t_1 + t_2 | X \geq t_2) = P(X \geq t_2)$
- **その他トピック:**
 - **偏差値:** $50 + 10 \times \frac{X - \mu}{\sigma}$
 - **指数分布の累積分布関数:** $F(x) = P(X \leq x) = 1 - e^{-\lambda x}$
 - **ガンマ関数:** $\Gamma(a) := \int_0^\infty x^{a-1} e^{-x} dx = (a-1)!, \quad a > 0$
 - **ガンマ分布と指数分布の関係:** $Ga(1, \frac{1}{\lambda}) = Exp(\lambda)$
 - **ベータ関数:** $B(a, b) := \int_0^1 x^{a-1} (1-x)^{b-1} dx, \quad a > 0, b > 0$
 - **ガンマ分布とベータ分布の関係:** $X_1 \sim Ga(a_1, b), X_2 \sim Ga(a_2, b) \Rightarrow \frac{X_1}{X_1 + X_2} \sim Be(a_1, a_2)$
 - **ベータ分布のモード:** $\frac{a-1}{a+b-2}$
 - **コーシー分布:** $f(x) = \frac{1}{\pi(1+x^2)}$ (※裾が重い分布、平均・分散・モーメント無し、原点对称)
 - t 分布の自由度を1とした場合と同一 (※そのため t 分布は自由度2以上で定義される)
 - **対数正規分布の原点周りの k 次モーメント:** $E[X^k] = \exp\left(\mu k + \frac{\sigma^2 k^2}{2}\right)$
 - **t 分布の定義:** $Z \sim N(0, 1), Y \sim \chi^2(n)$, 互いに独立 $\Rightarrow T = \frac{Z}{\sqrt{\frac{Y}{n}}}$
 - 母分散が未知の正規母集団において、標本平均 (分子の Z) を標本不偏分散 (分母の Y) で標準化した際の分布
 - **F 分布の定義:** $Z \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, 互いに独立 $\Rightarrow X = \frac{Y_1/n_1}{Y_2/n_2}$

極限定理・漸近理論

- **スルツキーの補題:** $X_n \Rightarrow X, Y_n \Rightarrow c$ のとき、 $X_n + Y_n \Rightarrow X + c, X_n Y_n \Rightarrow cX$
- **中心極限定理:** $\sqrt{n}(\bar{X} - \mu) \Rightarrow N(0, \sigma^2)$
- **デルタ法:** $\sqrt{n}(f(\bar{X}_n) - f(\mu)) \Rightarrow N(0, f'(\mu)^2 \sigma^2)$
 - $V(f(X)) \approx \{f'(E[X])\}^2 V(X)$

推定

- 尤度関数: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
- 対数尤度関数: $\log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$
- モーメント法: 理論値 = 標本値 と置く方程式
 - 原点周りのモーメント: $E[X^k] = \frac{1}{n} \sum_{i=1}^n x_i^k$
 - 中心周りのモーメント: $E[(X - \mu)^k] = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$
- バイアス: $b_\theta(\hat{\theta}) := E_\theta[\hat{\theta}] - \theta$
 - バイアスバリエーション分解: $E_\theta[(\hat{\theta} - \theta)^2] = (E_\theta[\hat{\theta}] - \theta)^2 + V_\theta[\hat{\theta}] = (b_\theta(\hat{\theta}))^2 + V_\theta[\hat{\theta}]$
- フィッシャー情報量: $J_n(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log L(\theta) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log L(\theta) \right]$
 - データ1個あたりの情報量: $J_1(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right]$
 - 標本が独立同一の場合: $J_n(\theta) = nJ_1(\theta)$
- クラメル・ラオの不等式: $V[\hat{\theta}] \geq \frac{1}{J_n(\theta)}$
 - 標本が独立同一の場合: $V[\hat{\theta}] \geq \frac{1}{nJ_1(\theta)}$
- 最尤推定量の漸近正規性 (標本サイズ $n \rightarrow \infty$ の大標本において): $\hat{\theta} \sim N \left(\theta, \frac{1}{nJ_1(\theta)} \right)$
 - 厳密な分布収束の表現: $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N \left(0, \frac{1}{J_1(\theta)} \right)$
- ジャックナイフ推定量: $\hat{\theta}_{jack} := n\hat{\theta} - (n - 1)\hat{\theta}_{(\cdot)}$ ($\hat{\theta}_{(\cdot)}$ は X_i を除いた推定量平均 $\frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(i)}$)

推定・検定

- 母平均の推定・検定:
 - 検定統計量 (標準正規分布): $Z = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}$
 - 95%信頼区間: $\bar{X} - Z_{0.025} \sqrt{\frac{\sigma^2}{n}} \leq \mu \leq \bar{X} + Z_{0.025} \sqrt{\frac{\sigma^2}{n}}$
- 母平均の推定・検定 (母分散未知):
 - 検定統計量 (t 分布): $t = \frac{\bar{X} - \mu}{\sqrt{s^2/n}} \sim t(n-1)$ (s^2 は不偏分散 $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$)
 - 95%信頼区間: $\bar{X} - t_{0.025}(n-1) \sqrt{\frac{s^2}{n}} \leq \mu \leq \bar{X} + t_{0.025}(n-1) \sqrt{\frac{s^2}{n}}$
- 母比率の推定・検定 (大標本近似):
 - 検定統計量 (標準正規分布): $Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$ (p_0 は帰無仮説における母比率)
 - 95%信頼区間: $\hat{p} - Z_{0.025} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + Z_{0.025} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ ($\hat{p}$ は標本比率 X/n 、大標本のため代用)
 - 多項分布: ある事象 A_i が起こるかどうかに着目して二項分布に帰着し、母比率の推定と同様に解く
- 分散の推定・検定:
 - 検定統計量 (カイ二乗分布): $\chi^2 = \frac{T^2}{\sigma^2} \sim \chi^2(n-1)$ (T^2 は偏差平方和 $\sum_{i=1}^n (X_i - \bar{X})^2$)
 - 95%信頼区間: $\chi_{0.975}^2(n-1) \leq \chi^2 \leq \chi_{0.025}^2(n-1) \iff \frac{T^2}{\chi_{0.025}^2(n-1)} \leq \sigma^2 \leq \frac{T^2}{\chi_{0.975}^2(n-1)}$

・ 分散の比の推定・検定:

- 検定統計量 (F 分布): $F = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ ($\ast s^2$ は不偏分散 $\frac{1}{n_k-1} \sum_{i=1}^{n_k} (X_{ki} - \bar{X}_k)^2$)
- 95%信頼区間: $F_{0.975}(n_1 - 1, n_2 - 1) \leq F \leq F_{0.025}(n_1 - 1, n_2 - 1)$
 $\iff \frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{0.025}(n_1-1, n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{0.975}(n_1-1, n_2-1)}$
 $\iff \frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{0.025}(n_1-1, n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{s_1^2}{s_2^2} \cdot F_{0.025}(n_2 - 1, n_1 - 1)$

・ ポアソン分布の検定

- 検定統計量 (標準正規分布): $Z = \frac{\hat{\lambda} - \lambda_0}{\sqrt{\lambda_0}}$
- 95%信頼区間: $\hat{\lambda} - Z_{0.025} \sqrt{\hat{\lambda}} \leq \lambda \leq \hat{\lambda} + Z_{0.025} \sqrt{\hat{\lambda}}$
- 適合度検定への拡張: $Z^2 = \frac{(\hat{\lambda} - \lambda_0)^2}{\lambda_0}$ は近似的に自由度1のカイ二乗分布に従う

・ 適合度検定

- 検定統計量 (カイ二乗分布): $\chi^2 = \sum_{i=1}^I \frac{(x_i - n\tilde{p}_i)^2}{n\tilde{p}_i} \sim \chi^2(I - 1 - d)$ ($\ast I$ はカテゴリ数、 d は固定したパラメータ、 $n\tilde{p}_i$ は期待度数)
- イエーツの補正 (自由度1のみ): サンプルサイズが小さい時に $(x_i - n\tilde{p}_i)^2$ を $(|x_i - n\tilde{p}_i| - 0.5)^2$ に置き換える (連続修正に対応)

・ 尤度比検定

- 尤度比: $\lambda_n = \frac{\text{制約なしの最大尤度}}{\text{帰無仮説の最大尤度}}$
- 検定統計量 (カイ二乗分布): $\chi^2 = 2 \log \lambda_n \sim \chi^2(p)$

・ 2つの母平均の差の推定・検定 (母分散既知を仮定):

- 検定統計量 (標準正規分布): $Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$
- 95%信頼区間: $(\bar{X}_1 - \bar{X}_2) - Z_{0.025} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq (\bar{X}_1 - \bar{X}_2) + Z_{0.025} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$

・ 2つの母平均の差の推定・検定 (母分散未知・等分散を仮定):

- 検定統計量 (t 分布): $t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{s^2(\frac{1}{n_1} + \frac{1}{n_2})}} \sim t(n_1 + n_2 - 2)$ ($\ast s^2$ は統合分散 $\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$)
- 95%信頼区間: $(\bar{X}_1 - \bar{X}_2) - t_{0.025}(n_1 + n_2 - 2) \sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \leq \mu_1 - \mu_2 \leq (\bar{X}_1 - \bar{X}_2) + t_{0.025}(n_1 + n_2 - 2) \sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$

・ 2つの母比率の差の推定・検定 (大標本近似):

- 検定統計量 (標準正規分布): $Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \hat{p}_* (1 - \hat{p}_*)}}$ ($\ast \hat{p}_*$ は $p_1 = p_2$ で $\hat{p}_* = (x_1 + x_2)/(n_1 + n_2)$)
- 95%信頼区間: $(\hat{p}_1 - \hat{p}_2) - Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} \leq p_1 - p_2 \leq (\hat{p}_1 - \hat{p}_2) + Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$

・ 2つの母比率の差の推定・検定 (多項分布で共分散を考慮する場合):

- 検定統計量（標準正規分布）： $Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}}}$
- 95%信頼区間： $(\hat{p}_1 - \hat{p}_2) - Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}} \leq p_1 - p_2 \leq (\hat{p}_1 - \hat{p}_2) + Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}}$
- サンプルサイズ設計
 - $Z_\alpha + Z_{1-\beta} = \frac{\mu_1 - \mu_0}{\sqrt{\sigma^2/n}} \iff n = \frac{(Z_\alpha + Z_{1-\beta})^2}{\left(\frac{\mu_1 - \mu_0}{\sigma}\right)^2} = \frac{(Z_\alpha + Z_{1-\beta})^2}{\Delta^2}$ （※ Δ は平均値の差と標準偏差の比、エフェクトサイズ）

過誤と評価指標

仮説検定の用語	記号	機械学習・分類の用語	計算式	意味の対応
第一種の過誤の確率	α	偽陽性率 (FPR)	$FP / (TN + FP)$	1－特異度、誤検知率、生産者危険
第二種の過誤の確率	β	偽陰性率 (FNR)	$FN / (TP + FN)$	1－感度、見逃し率、消費者危険
検出力	$1 - \beta$	真陽性率 / 感度 / 再現率	$TP / (TP + FN)$	正例を正しく拾い上げる割合
(特になし)	$1 - \alpha$	真陰性率 / 特異度	$TN / (TN + FP)$	負例を正しく弾く割合

- 機械学習・分類のみの指標
 - 正解率: $\frac{TP+TN}{ALL}$ 全体のうち正解したもの
 - 適合率: $\frac{TP}{TP+FP}$ 正例と判断したもののうち正例のもの
 - F値: $\frac{2 \times \text{適合率} \times \text{再現率}}{\text{適合率} + \text{再現率}}$

ノンパラメトリック法

- ウィルコクソンの順位和検定: 全データの順位をつけ、群の順位和を検定統計量とする
 - 対応のない2群の差の検定
 - 同じ値（タイ）の場合は平均順位を割り当て
 - サンプルサイズが大きくタイが無い場合は $N(m(m+n+1)/2, mn(m+n+1)/12)$ に近似
- 並べ替え検定: 全データを昇順に並び替え、群の平均を検定統計量とする
 - 対応のない2群の差の検定
- 符号付き順位検定: 全データを絶対値の昇順で並び替え、符号付き順位を割り当て、正值の合計順位を検定統計量とする
 - 対応のある2群の差の検定

- 0 は除外してサンプルサイズ n も減らす
- 同じ値（タイ）の場合は平均順位を割り当て
- 分布が左右対称であることが条件
- サンプルサイズが大きくタイが無い場合は $N(n(n+1)/4, n(n+1)(2n+1)/24)$ に近似
- **符号検定**: 正の値の個数を検定統計量とする ※二項分布 $Bin(n, 0.5)$ に従う
 - 対応のある2群の差の検定
 - 0 は除外してサンプルサイズ n も減らす
- **クラスカル・ウォリス検定**: 全データ（データ数 N ）の順位をつけ、各群 k の順位和から検定統計量を計算する
 - **検定統計量**: $H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_k^2}{n_k} - 3(N+1) \sim \chi^2(k-1)$ （※ R_k は順位和、 n_k はサンプルサイズ）
 - 対応のない3群以上の差の検定（一元配置分散分析のノンパラメトリック版）
- **順位相関係数**: 2次元データの順位の相関係数（※ x_i の昇順で並べると解きやすい）
 - **スピアマンの順位相関係数**: $r_s = 1 - \frac{6 \sum_{i=1}^n (x_i - y_i)^2}{n(n^2 - 1)}$
 - **ケンドールの順位相関係数**: $r_k = \frac{P - N}{n(n-1)/2}$ （※ $(x_i - x_j)(y_i - y_j)$ が正になる組数が P 、負になる組数が N ）

マルコフ連鎖

- **性質**: 現在の状態 X_n のみ（ X_{n-1} 以前の過去情報無し）で未来の状態 X_{n+1} が予測できる
- **mステップ推移確率**: $P_m^{(n)}(x, B) := P(X_{n+m} \in B | X_n = x), x \in S$
 - 推移確率が時点 n によらないとき、斉時的であるという（以降、離散的な状態空間を持つ有限かつ斉時的マルコフ連鎖を想定）
- **推移確率行列** $Q(m)$: $p_m(i, j) = P(X_{n+m} = j | X_n = i)$ の行列
 - $\sum_{j \in S} p_m(i, j) = 1$ （※各行の合計が1）
- **状態確率ベクトル**: $\pi_n = (p_n(1), p_n(2), \dots, p_n(N))$ （※ $p_n(k) := P(X_n = k)$ 、 P_n の総和は1）
 - $Q(m+l) = Q(m)Q(l) = Q^m Q^l$
 - $\pi_n = \pi_0 Q^n$
- **定常分布**: $\pi := \lim_{n \rightarrow \infty} \pi_n$ のとき $\pi = \pi Q$ （つまり π は行列 Q の固有値1に対する左固有ベクトル）
 - どの時点の状態確率ベクトルも π となる（初期分布が定常分布のものを定常マルコフ連鎖という）
- **有限マルコフ連鎖のパラメータ推定**:
 - **実現確率**: $P(X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) = P(X_n = x_n | X_{n-1} = x_{n-1})P(X_0 = x_0, X_1 = x_1, \dots, X_{n-1} = x_{n-1})$
 $= P(X_n = x_n | X_{n-1} = x_{n-1}) \dots P(X_1 = x_1 | X_0 = x_0)P(X_0 = x_0)$
 $= p_0(x_0) \prod_{j=1}^n P_\theta(x_{j-1}, x_j)$
 - **対数尤度関数**: $\ell_n(\theta) = \sum_{j=1}^n \log p_\theta(x_{j-1}, x_j)$
 - **独立同一な M 個のマルコフ連鎖の対数尤度関数**: $\ell_n(\theta) = \sum_{k=1}^M \sum_{j=1}^n \log p_\theta(x_{j-1}^{(k)}, x_j^{(k)})$

確率過程

- **独立増分性:** $X_{t_0}, X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$ が互いに独立
- **定常増分性:** $X_{t+h} - X_t$ の分布と $X_h - X_0$ の分布が同一
 - 独立増分性と定常増分性を満たす確率過程 X を独立定常増分過程という
- **ブラウン運動:** 「 $B_t \sim N(\mu t, \sigma^2 t)$ 」「独立定常増分過程」「パスが連続」を満たす確率過程
 - **標準ブラウン運動 (ウィナー過程):** $\mu = 0, \sigma^2 = 1$ となるブラウン運動
 - **ランダム・ウォーク:** $B_{t_k} = \sum_{i=1}^k \varepsilon_i, \varepsilon_i = B_{t_i} - B_{t_{i-1}}$ (※ $t_k = \frac{k}{n}$ は $[0, 1]$ を n 分割したうちの k 番目)
 - **パラメータ推定:** $B_t \sim N(\mu t, \sigma^2 t)$ のパスを時間間隔 $\Delta > 0$ で観測 ($B_0, B_\Delta, B_{2\Delta}, \dots, B_{n\Delta}$) して、 μ, σ^2 を推定
 - $Z_k := B_{k\Delta} - B_{(k-1)\Delta} \sim N(\mu\Delta, \sigma^2\Delta)$
 $\Rightarrow \hat{\mu}\Delta = \frac{1}{n} \sum_{k=1}^n Z_k, \hat{\sigma}^2\Delta = \frac{1}{n} \sum_{k=1}^n Z_k^2 - \left(\frac{1}{n} \sum_{k=1}^n Z_k\right)^2$ (※正規分布の最尤推定量)
 - $n \rightarrow \infty, \Delta \rightarrow 0$ で高頻度観測
- **ポアソン過程:** 「 $N_t \sim Po(\lambda t) \iff P(N_t = k) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$ 」「独立定常増分過程」を満たす確率過程