

統計検定準1級：統合メモ

数学公式一覧

指数

- ネイピア数 e の定義: $e = \lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n$
 - 無限級数による定義: $e = \sum_{n=0}^{\infty} \frac{1}{n!} = 1 + \frac{1}{1!} + \frac{1}{2!} + \frac{1}{3!} + \dots$
 - x 乗: $e^x = \lim_{n \rightarrow \infty} \left(1 + \frac{x}{n}\right)^n$
- 等比級数の和: $\sum_{x=0}^n ar^x = \frac{a(1-r^{n+1})}{1-r}$
 - 無限等比級数の和: $\sum_{x=0}^{\infty} ar^x = \frac{a}{1-r} \quad s.t. |r| < 1$
- 二項定理: $(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}$

対数

- 積から和: $\log(AB) = \log A + \log B$
- 商から差: $\log(A/B) = \log A - \log B$
- 累乗から係数: $\log(A^n) = n \log A$

マクローリン展開

- 公式: $f(x) = \sum_{n=0}^{\infty} \frac{f^{(n)}(0)}{n!} x^n$
- 指数関数の近似: $e^x \approx 1 + x + \frac{x^2}{2} \quad (x \text{ が微小のとき})$
- 対数関数の近似: $\log(1+x) \approx x - \frac{x^2}{2} \quad (x \text{ が微小のとき})$

微分

- ネイピア数の微分: $(e^{f(x)})' = f'(x)e^{f(x)}$
 - 指数部を微分したものだけをかけるだけ
 - 例) 定数係数: $(e^{kt})' = k \cdot e^{kt}$
 - 例) 二次係数: $(e^{-kx^2})' = -2kx \cdot e^{-kx^2}$
- 対数の微分: $(\log x)' = \frac{1}{x}$
 - 一般化: $(\log f(x))' = \frac{f'(x)}{f(x)}$
- $x \log x$ の微分: $(x \log x)' = \log x + 1$
- 積の微分: $(f(x)g(x))' = f'(x)g(x) + f(x)g'(x)$
- 商の微分: $\left(\frac{f(x)}{g(x)}\right)' = \frac{f'(x)g(x) - f(x)g'(x)}{g(x)^2}$
- 合成関数の微分: $\frac{d}{dx} f(g(x)) = f'(g(x)) \cdot g'(x)$

積分

- 指数関数の積分: $\int e^{kt} dt = \frac{1}{k} e^{kt}$
 - 指数部の逆数をかけるだけ
 - 例) 定数係数: $\int e^{kt} dt = \frac{1}{k} e^{kt} + C$
 - 負の指数関数の積分: $\int_0^{\infty} e^{-kt} dt = \frac{1}{k}$
- 自然対数の積分: $\int \log x dx = x \log x - x + C$
- 奇関数の対称区間での定積分: $\int_{-a}^a x^n dx = 0$ (n が奇数のとき)
- 置換積分: $\int f(g(x))g'(x)dx = \int f(u)du$ ($u = g(x)$)
- 部分積分: $\int f(x)g'(x)dx = f(x)g(x) - \int f'(x)g(x)dx$
- ガウス積分: $\int_{-\infty}^{\infty} e^{-ax^2} dx = \sqrt{\frac{\pi}{a}}$
 - 標準正規分布: $\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 1$
- ガンマ関数: $\Gamma(s) = \int_0^{\infty} x^{s-1} e^{-x} dx$
 - $\Gamma(n) = (n-1)!$
 - $\Gamma(s+1) = s\Gamma(s)$
 - $\Gamma(1/2) = \sqrt{\pi}$
- 指数関数と多項式の積の積分: $\int_0^{\infty} x^n e^{-ax} dx = \frac{n!}{a^{n+1}}$
- ベータ関数: $B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
- 極座標変換: $x = r \cos \theta, y = r \sin \theta$ のとき、 $dx dy = r dr d\theta$

ラグランジュの未定乗数法 (制約付き最適化)

- 目的: 制約条件 $g(\mathbf{x}) = 0$ の下で、関数 $f(\mathbf{x})$ の極値を求める。
- ラグランジュ関数: $L(\mathbf{x}, \lambda) = f(\mathbf{x}) - \lambda g(\mathbf{x})$
- 解法: 各変数と λ で偏微分して 0 と置いた連立方程式を解く。
 - $\frac{\partial L}{\partial x_i} = \frac{\partial f}{\partial x_i} - \lambda \frac{\partial g}{\partial x_i} = 0$ ($i = 1, 2, \dots, n$) (※ $\nabla f = \lambda \nabla g$ を意味する)
 - $\frac{\partial L}{\partial \lambda} = -g(\mathbf{x}) = 0$ (※ 制約条件 $g(\mathbf{x}) = 0$ そのもの)

行列

- 積の転置: $(AB)^T = B^T A^T$
- 積の逆行列: $(AB)^{-1} = B^{-1} A^{-1}$
- 転置の逆行列: $(A^T)^{-1} = (A^{-1})^T$
- 逆行列: $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ のとき、 $A^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$
- 行列式: $|A| = ad - bc$ (※ $ad - bc = 0$ のときは逆行列を持たない)
- ノルム: $\|\vec{x}\| = \sqrt{x_1^2 + x_2^2}$
- 内積 (スカラー): $\mathbf{x}^T \mathbf{y}$ は 1×1 の数値 (スカラー) になる
- 外積 (行列): $\mathbf{x} \mathbf{y}^T$ は行列になる
- 線形結合の微分: $\frac{\partial}{\partial \mathbf{x}} (\mathbf{a}^T \mathbf{x}) = \mathbf{a}$
- 二次形式の微分: $\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^T A \mathbf{x}) = 2A\mathbf{x}$ (※ A が対称行列の場合)
- 積のトレースの巡回不変性: $\text{tr}(AB) = \text{tr}(BA)$

- ・ **トレースと固有値**: $\text{tr}(A) = \sum \lambda_i$
- ・ **行列式の性質**: $|AB| = |A||B|$ 、 $|A^{-1}| = |A|^{-1}$
- ・ **行列式と固有値**: $|A| = \prod \lambda_i$
- ・ **対称行列**: $A^T = A$ を満たす行列
- ・ **べき等行列 (射影行列)**: $P^2 = P$ を満たす正方行列 P
 - べき等行列の固有値は 0 または 1 のみであり、 $\text{tr}(P) = \text{rank}(P)$ が成立
- ・ **ユークリッドノルムの2乗**: $\|\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{x}$
- ・ **マハラノビス汎距離 (の2乗)**: $(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$

確率

- ・ **ベイズの定理**: $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ 、事後確率 = $\frac{\text{尤度} \times \text{事前確率}}{\text{周辺尤度}}$

基本統計

- ・ **期待値 (離散型)**: $E[X] = \sum_x x p(x)$
- ・ **期待値 (連続型)**: $E[X] = \int_{-\infty}^{\infty} x f(x) dx$
- ・ **分散 (離散型)**: $V[X] = E[X^2] - (E[X])^2 = \sum_x (x - \mu)^2 p(x)$
- ・ **分散 (連続型)**: $V[X] = E[X^2] - (E[X])^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx = \int_{-\infty}^{\infty} x^2 f(x) dx - \left(\int_{-\infty}^{\infty} x f(x) dx \right)^2$
- ・ **共分散**: $\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$
- ・ **相関係数**: $\rho[X, Y] = E \left[\left(\frac{X - E[X]}{\sqrt{V[X]}} \right) \left(\frac{Y - E[Y]}{\sqrt{V[Y]}} \right) \right] = \frac{\text{Cov}[X, Y]}{\sqrt{V[X]V[Y]}}$
- ・ **偏相関係数**: $\rho[X, Y|Z] = \frac{\rho[X, Y] - \rho[X, Z]\rho[Y, Z]}{\sqrt{(1 - \rho[X, Z]^2)(1 - \rho[Y, Z]^2)}}$
- ・ **標準偏差**: $SD = \sigma = \sqrt{V[X]}$
- ・ **変動係数**: $CV = \frac{\sqrt{V[X]}}{E[X]}$
- ・ **確率密度関数**: $\int_{-\infty}^{\infty} f(x) dx = 1$
- ・ **累積分布関数**: $F(x) = \int_{-\infty}^x f(t) dt$
- ・ **生存関数**: $S(x) = 1 - F(x)$
- ・ **ハザード関数**: $h(x) = \frac{f(x)}{1 - F(x)} = \frac{f(x)}{S(x)} = (-\log S(x))'$
- ・ **確率母関数**: $G(s) = E[s^X] = \sum_x s^x p(x)$
 - $G'(s) = E[Xs^{X-1}]$ 、 $G''(s) = E[X(X-1)s^{X-2}]$
 - $G'(1) = E[X]$ 、 $G''(1) = E[X(X-1)] \iff E[X^2] = G''(1) + G'(1)$
 $\Rightarrow E[X] = G'(1)$ 、 $V[X] = E[X^2] - (E[X])^2 = G''(1) + G'(1) - (G'(1))^2$
 - $G^{(k)}(0) = k!P(X = k) \iff P(X = k) = \frac{G^{(k)}(0)}{k!}$ (確率母関数から確率を復元)
- ・ **モーメント母関数**: $m(t) = G(e^t) = E[e^{tX}]$
 - $m'(t) = E[Xe^{tX}]$ 、 $m''(t) = E[X^2e^{tX}]$
 - $m'(0) = E[X]$ 、 $m''(0) = E[X^2]$ 、 $m^{(k)}(0) = E[X^k]$

- $E[X] = m'(0)$ 、 $V[X] = E[X^2] - (E[X])^2 = m''(0) - (m'(0))^2$
- 独立な X_1 、 X_2 の和のモーメント母関数: $m(t) = m_1(t)m_2(t) \Rightarrow m_n(t) = m(t)^n$
- 歪度: $S[X] = \frac{E[X-E[X]]^3}{\sigma^3}$
 - $S[X] = \frac{E[X]^3}{\sigma^3} = \frac{m'''(0)}{m''(0)^{3/2}} \quad s.t. E[X] = 0$
- 尖度: $K[X] = \frac{E[X-E[X]]^4}{\sigma^4}$
 - $K[X] = \frac{E[X]^4}{\sigma^4} = \frac{m''''(0)}{m''(0)^2} \quad s.t. E[X] = 0$ 正規分布の場合は3

条件付き期待値/分散、全期待値/分散

- 条件付き確率（密度）: $f(y|x) = \frac{f(x,y)}{f_X(x)}$
- 条件付き期待値: $E[Y|X=x] = \int_{-\infty}^{\infty} y f(y|x) dy$ (※ x の関数になる)
- 全期待値の定理: $E[Y] = E_X[E[Y|X]]$
- 全分散の公式: $V[Y] = E_X[V_{Y|X}[Y|X]] + V_X[E_{Y|X}[Y|X]]$

平均

- 算術平均（相加平均）: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- 加重平均（重み付き平均）: $\bar{x}_w = \sum_{i=1}^n w_i x_i$
- 幾何平均（相乗平均）: $\bar{x}_g = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}} = \sqrt[n]{x_1 x_2 \cdots x_n}$
- 調和平均（割合平均）: $\bar{x}_h = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} = \left(\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i} \right)^{-1}$ (逆数の平均の逆数)
- 各種平均の大小関係: 調和平均 $\leq$ 幾何平均 $\leq$ 算術平均
 - 正の値の場合、等号成立は全データが等しい場合

変数変換

- 1変数の変数変換: $f_Y(y) = f_X(g^{-1}(y)) \left| \frac{dx}{dy} \right| = f_X(x) \left| \frac{dx}{dy} \right|$
- 2変数の変数変換: $f_{U,V}(u,v) = f_{X,Y}(x(u,v), y(u,v)) |J|$
- ヤコビアン: $J = \frac{\partial(x,y)}{\partial(u,v)} = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix} = \frac{\partial x}{\partial u} \frac{\partial y}{\partial v} - \frac{\partial x}{\partial v} \frac{\partial y}{\partial u}$
- 対数変換: $y = \log(x)$
- べき乗変換: $y = x^\lambda \quad \lambda = 0.5$ (平方根変換、ポアソン分布の分散安定用)、 -1 (逆数変換)
- Box-Cox変換: $y^{(\lambda)} = \begin{cases} \frac{x^\lambda - 1}{\lambda} & (\lambda \neq 0) \\ \log(x) & (\lambda = 0) \end{cases}$
- ロジット変換（対数オッズ）: $y = \log \left(\frac{p}{1-p} \right)$
 - ロジスティック回帰分析のリンク関数、逆変換でロジスティック関数（シグモイド関数）
- プロビット変換: $y = \Phi^{-1}(p)$ (Φ^{-1} は標準正規分布の累積分布関数の逆関数)
 - 確率 p を標準正規分布の z 値に変換

離散型分布

分布名	確率質量関数 (PMF)	期待値 $E[X]$	分散 $V[X]$	確率母関数 $G(s)$
離散一様分布 $DU(N)$	$\frac{1}{N}$	$\frac{N+1}{2}$	$\frac{N^2-1}{12}$	$\frac{s(1-e^{-Ns})}{N(1-s)}$
ベルヌーイ分布 $B(p), Bin(1, p)$	$p^x(1-p)^{1-x}$	p	$p(1-p)$	$ps + 1 - p$
二項分布 $Bin(n, p)$	${}_nC_x p^x (1-p)^{n-x}$	np	$np(1-p)$	$(ps + 1 - p)^n$
超幾何分布 $HG(N, M, n)$	$\frac{{}_M C_x \cdot {}_{N-M} C_{n-x}}{{}_N C_n}$	$n \frac{M}{N}$	$n \frac{M}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1}$	(省略)
ポアソン分布 $Po(\lambda)$	$\frac{\lambda^x e^{-\lambda}}{x!}$	λ	λ	$e^{\lambda(s-1)}$
幾何分布 $Geo(p)$ ※失敗回数 x	$p(1-p)^x$	$\frac{1-p}{p}$	$\frac{1-p}{p^2}$	$\frac{p}{1-(1-p)s}$
負の二項分布 $NB(r, p)$ ※失敗回数 y	${}_y C_{r-1} p^r (1-p)^y$	$\frac{r(1-p)}{p}$	$\frac{r(1-p)}{p^2}$	$\left(\frac{p}{1-(1-p)s}\right)^r$

- **多項分布:** 二項分布を多次元に拡張した分布
 - 期待値: $E[X_i] = np_i$
 - 分散: $V[X_i] = np_i(1-p_i)$
 - 共分散: $Cov(X_i, X_j) = -np_i p_j \quad s.t. i \neq j$ (※変数が独立でないため負の相関)
- **再生性:**
 - 二項分布: $X_1 \sim Bin(n_1, p), X_2 \sim Bin(n_2, p) \Rightarrow X_1 + X_2 \sim Bin(n_1 + n_2, p)$
 - ポアソン分布: $X_1 \sim Po(\lambda_1), X_2 \sim Po(\lambda_2) \Rightarrow X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)$
 - 負の二項分布: $X_1 \sim NB(r_1, p), X_2 \sim NB(r_2, p) \Rightarrow X_1 + X_2 \sim NB(r_1 + r_2, p)$
 - 多項分布: (省略)
- **無記憶性:**
 - 幾何分布: $X \sim Geo(p) \Rightarrow P(X \geq t_1 + t_2 | X \geq t_2) = P(X \geq t_2)$
- **用途:**
 - 超幾何分布: フィッシャーの正確検定

連続型分布

分布名	確率密度関数 (PDF)	期待値 $E[X]$	分散 $V[X]$	モーメント母関数 $M(t)$
連続一様分布 $U(a, b)$	$\frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{bt}-e^{at}}{(b-a)t}$
正規分布 $N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	μ	σ^2	$\exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$
標準正規分布 $N(0, 1)$	$\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$	0	1	$\exp\left(\frac{t^2}{2}\right)$
対数正規分布 $\Lambda(\mu, \sigma^2)$ ※ $\log X \sim N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma x} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right)$	$\exp\left(\mu + \frac{\sigma^2}{2}\right)$	$\exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1)$	(存在しない)
指数分布 $Exp(\lambda)$	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\frac{\lambda}{\lambda - t}$
ガンマ分布 $Ga(a, b)$	$\frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}}$	ab	ab^2	$(1 - bt)^{-a}$
ベータ分布 $Be(a, b)$	$\frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1}$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$	(省略)
カイ二乗分布 $\chi^2(n)$	$Ga\left(\frac{n}{2}, 2\right)$	n	$2n$	$(1 - 2t)^{-\frac{n}{2}}$
t分布 $t(n)$	(暗記不要)	0 ($n > 1$)	$\frac{n}{n-2}$ ($n > 2$)	(存在しない)
F分布 $F(n_1, n_2)$	(暗記不要)	$\frac{n_2}{n_2-2}$ ($n_2 > 2$)	(暗記不要)	(存在しない)

多変量正規分布:

- 条件付き期待値 (2変量) : $E[Y|X = x] = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)$
- 条件付き分散 (2変量) : $V[Y|X = x] = \sigma_Y^2 (1 - \rho^2)$
- モーメント母関数: $M(\mathbf{t}) = E[e^{\mathbf{t}^\top \mathbf{X}}] = \exp\left(\boldsymbol{\mu}^\top \mathbf{t} + \frac{1}{2} \mathbf{t}^\top \Sigma \mathbf{t}\right)$
- 無相関と独立: 多変量正規分布に従う場合に限り、「無相関 (共分散が0)」と「独立」は同値
- 条件付き期待値 (多変量) : $\boldsymbol{\mu}_{1|2} = \boldsymbol{\mu}_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2)$
- 線形変換: $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ 、 $\mathbf{Y} = A\mathbf{X} + \mathbf{b}$ の分布 $\Rightarrow \mathbf{Y} \sim N_q(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^\top)$

- **カイ二乗分布への接続:** 指数部分 $(\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu})$ 変数 $\mathbf{X}$ と平均 $\boldsymbol{\mu}$ の間の「マハラノビス距離の2乗」
 - $\mathbf{X}$ が p 変量正規分布に従うとき、この二次形式は自由度 p のカイ二乗分布 $\chi^2(p)$ に従う
- **混合正規分布:**
 - **確率密度関数:** $f(x) = p_1 f_1(x) + \cdots + p_K f_K(x)$ 混合比率 p で正規分布を混ぜた分布
 - **累積分布関数:** $F(x) = p_1 F_1(x) + \cdots + p_K F_K(x)$
 - **期待値:** $E[X] = \sum_{k=1}^K p_k \mu_k$
 - **分散:** $V[X] = \sum_{k=1}^K p_k \sigma_k^2$ 群内分散 + 群間分散
 - **二峰性条件:** $p_1 = p_2 = 0.5, \sigma_1 = \sigma_2 = \sigma \Rightarrow |\mu_1 - \mu_2| > 2\sigma$
- **再生性:**
 - **正規分布:** $X_1 \sim N(\mu_1, \sigma_1^2), X_2 \sim N(\mu_2, \sigma_2^2) \Rightarrow X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
 - **ガンマ分布:** $X_1 \sim Ga(a_1, b), X_2 \sim Ga(a_2, b) \Rightarrow X_1 + X_2 \sim Ga(a_1 + a_2, b)$
 - **カイ二乗分布:** $X_1 \sim \chi^2(n_1), X_2 \sim \chi^2(n_2) \Rightarrow X_1 + X_2 \sim \chi^2(n_1 + n_2)$
- **無記憶性:**
 - **指数分布:** $X \sim Exp(\lambda) \Rightarrow P(X \geq t_1 + t_2 | X \geq t_2) = P(X \geq t_2)$
- **その他トピック:**
 - **偏差値:** $50 + 10 \times \frac{X - \mu}{\sigma}$
 - **指数分布の累積分布関数:** $F(x) = P(X \leq x) = 1 - e^{-\lambda x}$
 - **ガンマ関数:** $\Gamma(a) := \int_0^\infty x^{a-1} e^{-x} dx = (a-1)!, \quad a > 0$
 - **ガンマ分布と指数分布の関係:** $Ga(1, \frac{1}{\lambda}) = Exp(\lambda)$
 - **ベータ関数:** $B(a, b) := \int_0^1 x^{a-1} (1-x)^{b-1} dx, \quad a > 0, b > 0$
 - **ガンマ分布とベータ分布の関係:** $X_1 \sim Ga(a_1, b), X_2 \sim Ga(a_2, b) \Rightarrow \frac{X_1}{X_1 + X_2} \sim Be(a_1, a_2)$
 - **ベータ分布のモード:** $\frac{a-1}{a+b-2}$
 - **コーシー分布:** $f(x) = \frac{1}{\pi(1+x^2)}$ (※裾が重い分布、平均・分散・モーメント無し、原点对称)
 - t 分布の自由度を1とした場合と同一 (※そのため t 分布は自由度2以上で定義される)
 - **対数正規分布の原点周りの k 次モーメント:** $E[X^k] = \exp\left(\mu k + \frac{\sigma^2 k^2}{2}\right)$
 - **t 分布の定義:** $Z \sim N(0, 1), Y \sim \chi^2(n)$, 互いに独立 $\Rightarrow T = \frac{Z}{\sqrt{\frac{Y}{n}}}$
 - 母分散が未知の正規母集団において、標本平均 (分子の Z) を標本不偏分散 (分母の Y) で標準化した際の分布
 - **F 分布の定義:** $Z \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, 互いに独立 $\Rightarrow X = \frac{Y_1/n_1}{Y_2/n_2}$

極限定理・漸近理論

- **スルツキーの補題:** $X_n \Rightarrow X, Y_n \Rightarrow c$ のとき、 $X_n + Y_n \Rightarrow X + c, X_n Y_n \Rightarrow cX$
- **中心極限定理:** $\sqrt{n}(\bar{X} - \mu) \Rightarrow N(0, \sigma^2) \iff (\bar{X} - \mu) \Rightarrow N(0, \frac{\sigma^2}{n})$
- **デルタ法:** $\sqrt{n}(f(\bar{X}_n) - f(\mu)) \Rightarrow N(0, f'(\mu)^2 \sigma^2)$

推定

- 尤度関数: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
- 対数尤度関数: $\log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$
- モーメント法: 理論値 = 標本値 と置く方程式
 - 原点周りのモーメント: $E[X^k] = \frac{1}{n} \sum_{i=1}^n x_i^k$
 - 中心周りのモーメント: $E[(X - \mu)^k] = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$
- バイアス: $b_\theta(\hat{\theta}) := E_\theta[\hat{\theta}] - \theta$
 - バイアスバリエンス分解: $E_\theta[(\hat{\theta} - \theta)^2] = (E_\theta[\hat{\theta}] - \theta)^2 + V_\theta[\hat{\theta}] = (b_\theta(\hat{\theta}))^2 + V_\theta[\hat{\theta}]$
- フィッシャー情報量: $J_n(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log L(\theta) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log L(\theta) \right]$
 - データ1個あたりの情報量: $J_1(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right]$
 - 標本が独立同一の場合: $J_n(\theta) = nJ_1(\theta)$
- クラメル・ラオの不等式: $V[\hat{\theta}] \geq \frac{1}{J_n(\theta)}$
 - 標本が独立同一の場合: $V[\hat{\theta}] \geq \frac{1}{nJ_1(\theta)}$
- 最尤推定量の漸近正規性 (標本サイズ $n \rightarrow \infty$ の大標本において): $\hat{\theta} \sim N \left(\theta, \frac{1}{nJ_1(\theta)} \right)$
 - 厳密な分布収束の表現: $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N \left(0, \frac{1}{J_1(\theta)} \right)$
- ジャックナイフ推定量: $\hat{\theta}_{jack} := n\hat{\theta} - (n-1)\hat{\theta}_{(\cdot)}$ (※ $\hat{\theta}_{(\cdot)}$ は X_i を除いた推定量平均 $\frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(i)}$)

推定・検定

- 母平均の推定・検定:
 - 検定統計量 (標準正規分布): $Z = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}$
 - 95%信頼区間: $\bar{X} - Z_{0.025} \sqrt{\frac{\sigma^2}{n}} \leq \mu \leq \bar{X} + Z_{0.025} \sqrt{\frac{\sigma^2}{n}}$
- 母平均の推定・検定 (母分散未知):
 - 検定統計量 (t 分布): $t = \frac{\bar{X} - \mu}{\sqrt{s^2/n}} \sim t(n-1)$ (※ s^2 は不偏分散 $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$)
 - 95%信頼区間: $\bar{X} - t_{0.025}(n-1) \sqrt{\frac{s^2}{n}} \leq \mu \leq \bar{X} + t_{0.025}(n-1) \sqrt{\frac{s^2}{n}}$
- 母比率の推定・検定 (大標本近似):
 - 検定統計量 (標準正規分布): $Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$ (※ p_0 は帰無仮説における母比率)
 - 95%信頼区間: $\hat{p} - Z_{0.025} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + Z_{0.025} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ (※ $\hat{p}$ は標本比率 X/n 、大標本のため代用)
 - 多項分布: ある事象 A_i が起こるかどうかに着目して二項分布に帰着し、母比率の推定と同様に解く
- 分散の推定・検定:
 - 検定統計量 (カイ二乗分布): $\chi^2 = \frac{T^2}{\sigma^2} \sim \chi^2(n-1)$ (※ T^2 は偏差平方和 $\sum_{i=1}^n (X_i - \bar{X})^2$)
 - 95%信頼区間: $\chi_{0.975}^2(n-1) \leq \chi^2 \leq \chi_{0.025}^2(n-1) \iff \frac{T^2}{\chi_{0.025}^2(n-1)} \leq \sigma^2 \leq \frac{T^2}{\chi_{0.975}^2(n-1)}$

・ 分散の比の推定・検定:

- 検定統計量 (F 分布): $F = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ ($\ast s^2$ は不偏分散 $\frac{1}{n_k-1} \sum_{i=1}^{n_k} (X_{ki} - \bar{X}_k)^2$)
- 95%信頼区間: $F_{0.975}(n_1 - 1, n_2 - 1) \leq F \leq F_{0.025}(n_1 - 1, n_2 - 1)$
 $\iff \frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{0.025}(n_1-1, n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{0.975}(n_1-1, n_2-1)}$
 $\iff \frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{0.025}(n_1-1, n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{s_1^2}{s_2^2} \cdot F_{0.025}(n_2 - 1, n_1 - 1)$

・ ポアソン分布の検定

- 検定統計量 (標準正規分布): $Z = \frac{\hat{\lambda} - \lambda_0}{\sqrt{\lambda_0}}$
- 95%信頼区間: $\hat{\lambda} - Z_{0.025} \sqrt{\hat{\lambda}} \leq \lambda \leq \hat{\lambda} + Z_{0.025} \sqrt{\hat{\lambda}}$
- 適合度検定への拡張: $Z^2 = \frac{(\hat{\lambda} - \lambda_0)^2}{\lambda_0}$ は近似的に自由度1のカイ二乗分布に従う

・ 適合度検定

- 検定統計量 (カイ二乗分布): $\chi^2 = \sum_{i=1}^I \frac{(x_i - n\tilde{p}_i)^2}{n\tilde{p}_i} \sim \chi^2(I - 1 - d)$ ($\ast I$ はカテゴリ数、 d は固定したパラメータ、 $n\tilde{p}_i$ は期待度数)
- イエーツの補正 (自由度1のみ): サンプルサイズが小さい時に $(x_i - n\tilde{p}_i)^2$ を $(|x_i - n\tilde{p}_i| - 0.5)^2$ に置き換える (連続修正に対応)

・ 尤度比検定

- 尤度比: $\lambda_n = \frac{\text{制約なしの最大尤度}}{\text{帰無仮説の最大尤度}}$
- 検定統計量 (カイ二乗分布): $\chi^2 = 2 \log \lambda_n \sim \chi^2(p)$

・ 2つの母平均の差の推定・検定 (母分散既知を仮定):

- 検定統計量 (標準正規分布): $Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$
- 95%信頼区間: $(\bar{X}_1 - \bar{X}_2) - Z_{0.025} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq (\bar{X}_1 - \bar{X}_2) + Z_{0.025} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$

・ 2つの母平均の差の推定・検定 (母分散未知・等分散を仮定):

- 検定統計量 (t 分布): $t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{s^2(\frac{1}{n_1} + \frac{1}{n_2})}} \sim t(n_1 + n_2 - 2)$ ($\ast s^2$ は統合分散 $\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$)
- 95%信頼区間: $(\bar{X}_1 - \bar{X}_2) - t_{0.025}(n_1 + n_2 - 2) \sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \leq \mu_1 - \mu_2 \leq (\bar{X}_1 - \bar{X}_2) + t_{0.025}(n_1 + n_2 - 2) \sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$

・ 2つの母比率の差の推定・検定 (大標本近似):

- 検定統計量 (標準正規分布): $Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \hat{p}_*(1-\hat{p}_*)}}$ ($\ast \hat{p}_*$ は $p_1 = p_2$ で $\hat{p}_* = (x_1 + x_2)/(n_1 + n_2)$)
- 95%信頼区間: $(\hat{p}_1 - \hat{p}_2) - Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} \leq p_1 - p_2 \leq (\hat{p}_1 - \hat{p}_2) + Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$

・ 2つの母比率の差の推定・検定 (多項分布で共分散を考慮する場合):

- 検定統計量（標準正規分布）： $Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}}}$
- 95%信頼区間： $(\hat{p}_1 - \hat{p}_2) - Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}} \leq p_1 - p_2 \leq (\hat{p}_1 - \hat{p}_2) + Z_{0.025} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}}$
- サンプルサイズ設計
 - $Z_\alpha + Z_{1-\beta} = \frac{\mu_1 - \mu_0}{\sqrt{\sigma^2/n}} \iff n = \frac{(Z_\alpha + Z_{1-\beta})^2}{\left(\frac{\mu_1 - \mu_0}{\sigma}\right)^2} = \frac{(Z_\alpha + Z_{1-\beta})^2}{\Delta^2}$ （※ Δ は平均値の差と標準偏差の比、エフェクトサイズ）

過誤と評価指標

仮説検定の用語	記号	機械学習・分類の用語	計算式	意味の対応
第一種の過誤の確率	α	偽陽性率 (FPR)	$FP / (TN + FP)$	1－特異度、誤検知率、生産者危険
第二種の過誤の確率	β	偽陰性率 (FNR)	$FN / (TP + FN)$	1－感度、見逃し率、消費者危険
検出力	$1 - \beta$	真陽性率(TPR) / 感度 / 再現率	$TP / (TP + FN)$	正例を正しく拾い上げる割合
(特になし)	$1 - \alpha$	真陰性率(TNR) / 特異度	$TN / (TN + FP)$	負例を正しく弾く割合

- 機械学習・分類のみの指標
 - 正解率: $\frac{TP+TN}{ALL}$ 全体のうち正解したもの
 - 適合率: $\frac{TP}{TP+FP}$ 正例と判断したもののうち正例のもの
 - F値: $\frac{2 \times \text{適合率} \times \text{再現率}}{\text{適合率} + \text{再現率}}$
- ROC曲線: 縦軸を真陽性率(TPR)、横軸を偽陽性率(FPR)とした曲線、下側面積(AUC) [0.5, 1] で全体的な判別機の性能を評価

ノンパラメトリック法

- ウィルコクソンの順位和検定: 全データの順位をつけ、群の順位和を検定統計量とする
 - 対応のない2群の差の検定
 - 同じ値（タイ）の場合は平均順位を割り当て
 - サンプルサイズが大きくタイが無い場合は $N(m(m+n+1)/2, mn(m+n+1)/12)$ に近似
- 並べ替え検定: 全データを昇順に並び替え、群の平均を検定統計量とする
 - 対応のない2群の差の検定

- **符号付き順位検定:** 全データを絶対値の昇順で並び替え、符号付き順位を割り当て、正值の合計順位を検定統計量とする
 - 対応のある2群の差の検定
 - 0 は除外してサンプルサイズ n も減らす
 - 同じ値（タイ）の場合は平均順位を割り当て
 - 分布が左右対称であることが条件
 - サンプルサイズが大きくタイが無い場合は $N(n(n+1)/4, n(n+1)(2n+1)/24)$ に近似
- **符号検定:** 正の値の個数を検定統計量とする ※二項分布 $Bin(n, 0.5)$ に従う
 - 対応のある2群の差の検定
 - 0 は除外してサンプルサイズ n も減らす
- **クラスカル・ウォリス検定:** 全データ（データ数 N ）の順位をつけ、各群 k の順位和から検定統計量を計算する
 - **検定統計量:** $H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_k^2}{n_k} - 3(N+1) \sim \chi^2(k-1)$ （※ R_k は順位和、 n_k はサンプルサイズ）
 - 対応のない3群以上の差の検定（一元配置分散分析のノンパラメトリック版）
- **順位相関係数:** 2次元データの順位の相関係数 （※ x_i の昇順で並べると解きやすい）
 - **スピアマンの順位相関係数:** $r_s = 1 - \frac{6 \sum_{i=1}^n (x_i - y_i)^2}{n(n^2 - 1)}$
 - **ケンドールの順位相関係数:** $r_k = \frac{P - N}{n(n-1)/2}$ （※ $(x_i - x_j)(y_i - y_j)$ が正になる組数が P 、負になる組数が N ）

マルコフ連鎖

- **性質:** 現在の状態 X_n のみ（ X_{n-1} 以前の過去情報無し）で未来の状態 X_{n+1} が予測できる
- **mステップ推移確率:** $P_m^{(n)}(x, B) := P(X_{n+m} \in B | X_n = x), x \in S$
 - 推移確率が時点 n によらないとき、斉時的であるという（以降、離散的な状態空間を持つ有限かつ斉時的マルコフ連鎖を想定）
- **推移確率行列 $Q(m)$:** $p_m(i, j) = P(X_{n+m} = j | X_n = i)$ の行列
 - $\sum_{j \in S} p_m(i, j) = 1$ （※各行の合計が1）
- **状態確率ベクトル:** $\pi_n = (p_n(1), p_n(2), \dots, p_n(N))$ （※ $p_n(k) := P(X_n = k)$ 、 P_n の総和は1）
 - $Q(m+l) = Q(m)Q(l) = Q^m Q^l$
 - $\pi_n = \pi_0 Q^n$
- **定常分布:** $\pi := \lim_{n \rightarrow \infty} \pi_n$ のとき $\pi = \pi Q$ （つまり π は行列 Q の固有値1に対する左固有ベクトル）
 - どの時点の状態確率ベクトルも π となる（初期分布が定常分布のものを定常マルコフ連鎖という）
- **有限マルコフ連鎖のパラメータ推定:**
 - **実現確率:** $P(X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) = P(X_n = x_n | X_{n-1} = x_{n-1})P(X_0 = x_0, X_1 = x_1, \dots, X_{n-1} = x_{n-1})$

- $$= P(X_n = x_n | X_{n-1} = x_{n-1}) \dots P(X_1 = x_1 | X_0 = x_0) P(X_0 = x_0)$$
- $$= p_0(x_0) \prod_{j=1}^n P_\theta(x_{j-1}, x_j)$$
- 対数尤度関数: $\ell_n(\theta) = \sum_{j=1}^n \log p_\theta(x_{j-1}, x_j)$
 - 独立同一な M 個のマルコフ連鎖の対数尤度関数: $\ell_n(\theta) = \sum_{k=1}^M \sum_{j=1}^n \log p_\theta(x_{j-1}^{(k)}, x_j^{(k)})$

確率過程

- 独立増分性: $X_{t_0}, X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$ が互いに独立
- 定常増分性: $X_{t+h} - X_t$ の分布と $X_h - X_0$ の分布が同一
 - 独立増分性と定常増分性を満たす確率過程 X を独立定常増分過程という
- ブラウン運動: 「 $B_t \sim N(\mu t, \sigma^2 t)$ 」「独立定常増分過程」「パスが連続」を満たす確率過程
 - 標準ブラウン運動 (ウィナー過程): $\mu = 0, \sigma^2 = 1$ となるブラウン運動
 - ランダム・ウォーク: $B_{t_k} = \sum_{i=1}^k \varepsilon_i, \varepsilon_i = B_{t_i} - B_{t_{i-1}}$ ($\ast t_k = \frac{k}{n}$ は $[0, 1]$ を n 分割したうちの k 番目)
 - パラメータ推定: $B_t \sim N(\mu t, \sigma^2 t)$ のパスを時間間隔 $\Delta > 0$ で観測 ($B_0, B_\Delta, B_{2\Delta}, \dots, B_{n\Delta}$) して、 μ, σ^2 を推定
 - $Z_k := B_{k\Delta} - B_{(k-1)\Delta} \sim N(\mu\Delta, \sigma^2\Delta)$
 $\Rightarrow \hat{\mu}\Delta = \frac{1}{n} \sum_{k=1}^n Z_k, \hat{\sigma}^2\Delta = \frac{1}{n} \sum_{k=1}^n Z_k^2 - \left(\frac{1}{n} \sum_{k=1}^n Z_k\right)^2$ ($\ast$ 正規分布の最尤推定量)
 - $n \rightarrow \infty, \Delta \rightarrow 0$ で高頻度観測
- ポアソン過程: 「 $N_t \sim Po(\lambda t) \iff P(N_t = k) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$ 」「独立定常増分過程」を満たす確率過程
 - 計数過程/点過程: $N_t = \sum_{k=1}^\infty I(T_k \leq t)$ ($\ast I$ はイベントが発生したときのみ 1)
 - 発生間隔: $W_k = T_k - T_{k-1} \sim Exp(\lambda) \Rightarrow N_t \sim Po(\lambda t)$
 - パラメータ推定: $\hat{\lambda} = \frac{\text{イベントの総回数}}{\text{観測時間}}$ ($\ast$ 一様性、漸近正規性がある)
 - 複合ポアソン過程: $X_t = \sum_{k=1}^{N_t} U_k$ ($\ast N$ がポアソン過程、 U_k が互いに独立同一かつ N と独立)
 - 平均: $E[X_t] = E[N_t]E[U_k] = \lambda t E[U_k]$ ($\ast N, U_k$ が独立)
 - 分散: $V[X_t] = \lambda t E[(U_k)^2]$

重回帰分析

- モデル: $y = \beta_0 + \beta_1 x_1 + \dots + \beta_d x_d + \varepsilon$
- 最小二乗推定量 (不偏推定量): $\hat{\beta} = (X^\top X)^{-1} X^\top Y$
 - 予測値ベクトル: $\hat{y} = X\hat{\beta} = X(X^\top X)^{-1} X^\top Y$
 - 残差ベクトル: $e = Y - X\hat{\beta} = (I - X(X^\top X)^{-1} X^\top) Y$
- 分散の不偏推定量 (最小分散): $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - (1, \mathbf{x}_i^\top) \hat{\beta})^2}{n-d-1}$
- 決定係数: $R^2 = \frac{\text{回帰変動}}{\text{総変動}} = \frac{\sum_{i=1}^n ((\mathbf{x}_i - \bar{\mathbf{x}})^\top \hat{\beta}_{1:d})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n (y_i - (1, \mathbf{x}_i^\top) \hat{\beta})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$
- 自由度調整済み決定係数: $R^{*2} = 1 - \frac{n-1}{n-d-1} (1 - R^2)$

- 回帰係数の検定 (1変数) : $T = \frac{\hat{\beta}_k}{SE} \sim t(n - d - 1)$
 - 95%信頼区間: $\hat{\beta}_k \pm t_{0.025}(n - d - 1) \times SE$
- 回帰係数の検定 (全体) : $T = \frac{\|X\hat{\beta} - \mathbf{1}\bar{y}\|^2/d}{\hat{\sigma}^2} \sim F(d, n - d - 1)$
- 正則化: 回帰係数の推定量の分散を抑えて過適合 (過学習) を防ぐ
 - L_2 -正則化 (リッジ回帰) : $\hat{\beta}_R = \arg \min_{\beta} (\|Y - X\beta\|^2 + \lambda \sum_{j=0}^d \beta_j^2)$
 - パラメータの二乗和に比例したペナルティ (二乗和なのでパラメータは 0 にはならない)
 - 極端に大きな値のパラメータを抑え込んでモデルの安定化を図る
 - L_1 -正則化 (Lasso回帰) : $\hat{\beta}_L = \arg \min_{\beta} (\|Y - X\beta\|^2 + \lambda \sum_{j=0}^d |\beta_j|)$
 - パラメータの絶対値の和に比例したペナルティ (影響力の低いパラメータは 0 になる)
 - 不要なパラメータの削減を図る
 - Elastic-Net: $\alpha \sum_{j=1}^d |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^d \beta_j^2$
 - リッジ回帰とLasso回帰のバランス、パラメータを削減しつつ極端に大きな値のパラメータも防ぐ
 - Fused lasso: $\|Y - X\beta\|^2 + \lambda \sum_{k=1}^{d-1} |\beta_k - \beta_{k+1}|$
 - 主に時系列解析で用いられ、隣接パラメータが似ていると考えられる際に、差が 0 になるよう正則化
 - パラメータが「階段状」に変化するようなモデルを作る際に特化して使われる

回帰診断法

- 残差プロット: 残差の等分散性を確認するため、縦軸に残差、横軸に予測値をプロットしたもの
- 正規Q-Qプロット: 誤差項の正規性を確認するため、縦軸に標準化残差、横軸に標準正規分布の累積分布関数の分位点をプロットしたもの
- 標準化残差の絶対値の平方根プロット: 残差の等分散性を確認するため、縦軸に標準化残差の絶対値の平方根、横軸に予測値をプロットしたもの
- leverage (てこ比、てこ値) : ハット行列 $H = X(X^T X)^{-1} X^T$ の i 番目の対角要素 h_{ii}
 - モデルへの影響度を示す
- Cookの距離: 標準化残差と $h_{ii}/(1 - h_{ii})$ によって計算される
 - i 番目の観測値を除いた場合の予測値との差異、0.5 以上で外れ値とされる

質的回帰

- ロジスティック回帰モデル: $\log \frac{\pi}{1-\pi} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$
 - リンク関数がロジット関数、生起確率がベルヌーイ分布
 - ロジット変換: $\pi \mapsto \log \frac{\pi}{1-\pi}$
 - ロジスティック変換: $x \mapsto \frac{e^x}{1+e^x}$
 - 対数尤度関数: $\log \left(\prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i} \right) = \sum_{i=1}^n \left(y_i \log \frac{\pi_i}{1-\pi_i} + \log(1 - \pi_i) \right) = \mathbf{y}^T X\beta - \sum_{i=1}^n \log(1 + e^{x_i^T \beta})$

- 生起確率推定量: $\hat{\pi}_i = \frac{\exp(\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip})}{1 + \exp(\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip})} = \frac{\exp(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})}{1 + \exp(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})}$
 - オッズ比: x_j が 1 増加したとき e^{β_j} 倍
- プロビットモデル**: $\pi = \Phi(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)$
 - リンク関数がプロビット関数、生起確率がベルヌーイ分布
 - プロビット変換**: $\pi \mapsto \Phi^{-1}(\pi)$
 - 対数尤度関数**:
$$\sum_{i=1}^n \left[y_i \log \Phi \left(\beta_0 + \sum_{j=1}^p \beta x_{ij} \right) + (1 - y_i) \log \left(1 - \Phi \left(\beta_0 + \sum_{j=1}^p \beta x_{ij} \right) \right) \right]$$
 - 生起確率推定量: $\hat{\pi}_i = \Phi(\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip}) = \Phi(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})$
 - 限界効果**: $\frac{\partial \pi}{\partial x_j} = \frac{\partial \Phi(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}{\partial x_j} = \varphi(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p) \beta_j$
- ポアソン回帰モデル (対数線形モデル)**: $\log \pi = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$
 - リンク関数が対数関数、生起確率がポアソン分布
 - 対数尤度関数**: $\log \left(\prod_{i=1}^n e^{-\pi_i} \frac{\pi_i^{y_i}}{y_i!} \right) = \mathbf{y}^\top X \boldsymbol{\beta} - \sum_{i=1}^n \log(e^{\mathbf{x}_i^\top \boldsymbol{\beta}} + \log y_i!)$
 - 生起確率変化: x_j が 1 増加したとき e^{β_j} 倍
- 指数分布族**: $f(y; \theta, \phi) = \exp \left[\frac{y\theta - b(\theta)}{a(\phi)} - c(y, \phi) \right]$
 - リンク関数**: $g(\pi) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$
 - 期待値**: $\pi = E[Y] = b'(\theta)$
 - 分散**: $V[Y] = b''(\theta)a(\phi)$
 - 正規分布**: $f(y; \theta, \phi) = \exp \left[\frac{y\mu - \frac{1}{2}\mu^2}{\sigma^2} - \frac{1}{2} \left(\frac{y^2}{\sigma^2} + \log(2\pi\sigma^2) \right) \right]$
 - $\theta = \mu, \phi = \sigma^2, a(\phi) = \phi, b(\theta) = \frac{1}{2}\theta^2, c(y, \phi) = \frac{1}{2} \left(\frac{y^2}{\phi} + \log(2\pi\phi) \right)$
 - ベルヌーイ分布**: $f(y; \theta) = \exp \left[y \log \left(\frac{\pi}{1-\pi} \right) - \log(1 + e^\theta) \right]$
 - $\theta = \log \frac{\pi}{1-\pi}, a(\phi) = 1, b(\theta) = \log(1 + e^\theta), c(y, \phi) = 0$
 - ポアソン分布**: $f(y; \theta) = \exp [y \log \pi - \pi - \log y!]$
 - $\theta = \log \pi, a(\phi) = 1, b(\theta) = e^\theta, c(y, \phi) = \log y!$

回帰分析その他

- トービットモデル**: 被説明変数に観測限界 (速度計, GPA評価点, etc) がある場合のモデル、左打ち切り・右打ち切り・両側打ち切り
 - タイプ I トービットモデル**: 説明変数 $\mathbf{x}_i$ は観測可能、観測値 y_i は打ち切りのモデル
 - y_i^* を潜在変数と呼ぶ
 - 尤度関数 (左打ち切り)**:
$$L(\boldsymbol{\beta}, \sigma) = \prod_{i=1}^n \left[\frac{1}{\sigma} \phi \left(\frac{y_i - \mathbf{x}_i^\top \boldsymbol{\beta}}{\sigma} \right) \right]^{I(y_i)} \left[1 - \Phi \left(\frac{\mathbf{x}_i^\top \boldsymbol{\beta} - L}{\sigma} \right) \right]^{1 - I(y_i)}$$

$$= \prod_{i: y_i > L} \frac{1}{\sigma} \phi \left(\frac{y_i - \mathbf{x}_i^\top \boldsymbol{\beta}}{\sigma} \right) \prod_{i: y_i \leq L} \Phi \left(\frac{L - \mathbf{x}_i^\top \boldsymbol{\beta}}{\sigma} \right)$$
- 生存時間解析**: $S(t) = P(T > t) = \int_t^\infty f(x|\boldsymbol{\theta}) dx$
 - ハザード関数**: $h(t) = \frac{f(t)}{1-F(t)} = \frac{f(t)}{S(t)} = -\frac{S'(t)}{S(t)} = (-\log S(t))'$
 - 指数分布**: $f(t) = \lambda e^{-\lambda t}$
 - 生存関数**: $S(t) = e^{-\lambda t}$

- ハザード関数: $h(t) = \lambda$ (※定常なハザード)
- ワイブル分布: $f(t) = \lambda p(\lambda t)^{p-1} e^{-(\lambda t)^p}$
 - 生存関数: $S(t) = e^{-(\lambda t)^p}$
 - ハザード関数: $h(t) = \lambda p(\lambda t)^{p-1}$ (※ $p > 1$ で単調増加、 $p < 1$ で単調減少)
- 対数正規分布: $f(t) = (\sqrt{2\pi\sigma t})^{-1} e^{-(\log t - \mu)^2 / (2\sigma^2)}$
 - 生存関数: $S(t) = 1 - \Phi\left(\frac{\log t - \mu}{\sigma}\right)$
 - 増加から減少に転じるハザード関数
- 比例ハザードモデル: $h(t; \mathbf{x}) = \exp(\alpha + \mathbf{x}^\top \boldsymbol{\beta}) = h_0 e^{\mathbf{x}^\top \boldsymbol{\beta}}$, ($h_0 = e^\alpha > 0$)
 - Cox比例ハザードモデル: $h(t; \mathbf{x}) = h_0(t) e^{\mathbf{x}^\top \boldsymbol{\beta}}$, ($h_0(t) > 0$)
 - $h_0(t)$ の形を指定しないためセミ・パラメトリックモデル
 - 比例ハザード性: $\frac{h(t; \mathbf{x})}{h(t; \mathbf{x}^*)} = \exp[(\mathbf{x} - \mathbf{x}^*)^\top \boldsymbol{\beta}]$ (※時間に依存しない)
 - 比例ハザード性の検証: $\log(-\log S(t; \mathbf{x})) = \mathbf{x}^\top \boldsymbol{\beta} + \log H_0(t)$
- カプラン・マイヤー推定量: $\hat{S}(t) = \begin{cases} 1 & (t < t_1) \\ \prod_{i:t_i \leq t} \frac{n_i - d_i}{n_i} & (t \geq t_1) \end{cases}$
 - $\hat{S}(t_j) = \hat{S}(t_{j-1}) \times \hat{P}[T > t_j | T \geq t_j] \iff \hat{S}(t_j) = \prod_{i=1}^j \hat{P}[T > t_j | T \geq t_j]$
- ニューラルネットワークモデル: $\mathbf{y} = h_{\theta''}(g_{\theta'}(f_{\theta}(\mathbf{x})))$ (※ θ は重みベクトルやバイアス項からなるパラメータベクトル)
 - $\mathbf{x} \Rightarrow f_{\theta} \Rightarrow g_{\theta'} \Rightarrow h_{\theta''}$ と多段階 (途中を中間層と呼ぶ) で変換されて出力される
 - 中間層が多いものを深層ニューラルネットワークと呼ぶ

分散分析と実験計画法

- フィッシャーの三原則:
 - replication : 反復, 繰り返し: 誤差による変動の評価を行う
 - randomization : ランダム化, 無作為化: 処理による変動と無関係要因による変動を分けるため
 - local control : 局所管理, 小分けの原理: 局所的に均一な場を用意して処理以外の影響 (ブロック因子) を取り除く
- 一元配置分散分析表:

要因	平方和(S)	自由度(ϕ)	平均平方/分散 (V)	F 値【S/N比】
要因 (群間)	S_A	$\phi_A = a - 1$	$V_A = \frac{S_A}{\phi_A}$	$F = \frac{V_A}{V_E} \sim F(\phi_A, \phi_E)$
残差 (群内)	S_E	$\phi_E = a(n - 1)$	$V_E = \frac{S_E}{\phi_E}$	
全体	S_T	$\phi_T = an - 1$		

- 点推定: $\bar{y}_{A_i} \pm t_{0.025}(\phi_E) \sqrt{V_E/n}$
- 二元配置分散分析表:

要因	平方和 (S)	自由度(ϕ)	平均平方/分散 (V)	F値【S/N比】
要因A	S_A	$\phi_A = a - 1$	$V_A = \frac{S_A}{\phi_A}$	$F_A = \frac{V_A}{V_E} \sim F(\phi_A, \phi_E)$
要因B	S_B	$\phi_B = b - 1$	$V_B = \frac{S_B}{\phi_B}$	$F_B = \frac{V_B}{V_E} \sim F(\phi_B, \phi_E)$
交互作用	$S_{A \times B}$	$\phi_{A \times B} = (a - 1)(b - 1)$	$V_{A \times B} = \frac{S_{A \times B}}{\phi_{A \times B}}$	$F_{A \times B} = \frac{V_{A \times B}}{V_E} \sim F(\phi_{A \times B}, \phi_E)$
残差	S_E	$\phi_E = ab(n - 1)$	$V_E = \frac{S_E}{\phi_E}$	
全体	S_T	$\phi_T = abn - 1$		

・ 一元配置乱塊法:ブロック因子の導入:

要因	平方和 (S)	自由度(ϕ)	平均平方/分散 (V)	F値【S/N比】
要因A	S_A	$\phi_A = a - 1$	$V_A = \frac{S_A}{\phi_A}$	$F_A = \frac{V_A}{V_E} \sim F(\phi_A, \phi_E)$
ブロック因子	S_R	$\phi_R = r - 1$	$V_R = \frac{S_R}{\phi_R}$	$F_R = \frac{V_R}{V_E} \sim F(\phi_R, \phi_E)$
残差	S_E	$\phi_E = (a - 1)(r - 1)$	$V_E = \frac{S_E}{\phi_E}$	
全体	S_T	$\phi_T = ar - 1$		

・ 二元配置乱塊法:ブロック因子の導入:

要因	平方和 (S)	自由度(ϕ)	平均平方/分散 (V)	F値【S/N比】
要因A	S_A	$\phi_A = a - 1$	$V_A = \frac{S_A}{\phi_A}$	$F_A = \frac{V_A}{V_E} \sim F(\phi_A, \phi_E)$
要因B	S_B	$\phi_B = b - 1$	$V_B = \frac{S_B}{\phi_B}$	$F_B = \frac{V_B}{V_E} \sim F(\phi_B, \phi_E)$
交互作用	$S_{A \times B}$	$\phi_{A \times B} = (a - 1)(b - 1)$	$V_{A \times B} = \frac{S_{A \times B}}{\phi_{A \times B}}$	$F_{A \times B} = \frac{V_{A \times B}}{V_E} \sim F(\phi_{A \times B}, \phi_E)$
ブロック因子	S_R	$\phi_R = r - 1$	$V_R = \frac{S_R}{\phi_R}$	$F_R = \frac{V_R}{V_E} \sim F(\phi_R, \phi_E)$
残差	S_E	$\phi_E = (ab - 1)(r - 1)$	$V_E = \frac{S_E}{\phi_E}$	
全体	S_T	$\phi_T = abr - 1$		

- 直交表:

- 成分記号の計算: $abc^2 = ab$ (※同一成分の二乗は1となる)
- 平方和: $S_{[k]} = \frac{N}{4}(\bar{y}_{[k]1} - \bar{y}_{[k]2})^2$ (※直交表の k 列が1の平均と2の平均の差の二乗)
- 自由度: $\phi = (\text{水準数} - 1)$ (※2水準の場合は1)
 - 誤差の自由度は割付のない列数倍
- 点推定: $\bar{y}_{A_i} \pm t_{0.025}(\phi_E) \sqrt{\frac{2}{N} V_E}$

標本調査法

- 単純無作為抽出法: 抽出全体を通じて母集団の各抽出単位の選ばれる確率が等しい抽出方法
 - 有意選出法: 平均的なサンプルを抽出するなど主観や意図が入る方法
 - 非復元抽出: 同じ抽出単位を2回以上抽出しない方法
 - 期待値/分散: $E[\bar{x}] = \mu, V[\bar{x}] = \frac{N-n}{N-1} \cdot \frac{1}{n} \sigma^2$
- 集落(クラスター)抽出法: 母集団を集落に分けた上で集落全体を調査する方法
 - 調査しやすいが集落の影響が大きくなってしまう
- 二段(多段)抽出法: グループを選んだあとグループ内から選ぶ方法
- 系統的抽出法: リスト上で等間隔に選んでいく方法
 - 単純無作為抽出法と異なり、すべての標本に採番する必要がない
- 層化抽出法: 層に分けた上で各層から決まった大きさを抽出する方法
 - 母集団全体から偏りなく抽出ができる
 - 層内はできるだけ均質に、異なる層はできるだけ異質にする
 - 層化(非復元)無作為抽出法: $\bar{x}_{st} = \sum_{h=1}^L \frac{N_h}{N} \cdot \frac{1}{n_h} \sum_{i=1}^{n_h} x_{hi}$
 - L は層数、 N_h は各層内の総数、 n_h は各層からの抽出数
 - 期待値/分散: $E[\bar{x}] = \mu, V[\bar{x}_{st}] = \sum_{h=1}^L \left(\frac{N_h}{N}\right)^2 \cdot \frac{N_h - n_h}{N_h - 1} \cdot \frac{1}{n_h} \sum_{i=1}^{n_h} \sigma_h^2$
 - 標本配分法:
 - 比例配分法: $n_h = \frac{N_h}{N} \times n$
 - 推定量の精度は単純無作為抽出よりも悪くなることはない
 - 等配分法: $n_h = \frac{n}{L}$
 - ネイマン配分法/最適配分法: $n_h = \frac{N_h \times \sigma \times \sqrt{\frac{N_h}{N_h - 1}}}{\sum_{h=1}^L N_h \times \sigma \times \sqrt{\frac{N_h}{N_h - 1}}} \times n$

主成分分析

- 中心化行列: $X_C = (x_{i,j} - \bar{x}_{.j})_{1 \leq i \leq n, 1 \leq j \leq p} = \left(I_n - \frac{1}{n} J_n\right) X$ (※ Z_C も同様)
- 中心化行列を用いた標本分散共分散行列: $S = \frac{1}{n-1} X_C^\top X_C$
- 中心化行列を用いた標本相関行列: $R = \frac{1}{n-1} Z^\top Z = \frac{1}{n-1} Z_C^\top Z_C$ (※ $z_{i,j} = (x_{i,j} - \bar{x}_{.j}) / \sqrt{s_{j,j}}$ で標本データを標準化)
- 対角化: $U^\top S U = \text{diag}(\lambda_1, \dots, \lambda_p)$

- 固有値問題への帰着: $S\mathbf{u}_j = \lambda_j \mathbf{u}_j$, $\langle \mathbf{u}_j, \mathbf{u}_k \rangle = \delta_{j,k}$ ($\delta_{j,k}$ はクロネッカーデルタの記号、 $j = k$ で 1、 $j \neq k$ で 0)
- 第 j 主成分: $y_j = \langle \mathbf{u}_j, \mathbf{x} \rangle = x_1 u_{1,j} + \cdots + x_p u_{p,j}$
- 寄与率: $c_j = \frac{\lambda_j}{\lambda_1 + \cdots + \lambda_p}$
- 主成分得点: $\{y_{i,j} = \langle \mathbf{x}_i, \mathbf{u}_j \rangle\}$ ($\times$ 中心化されたデータと主成分の固有ベクトルの内積)
- 主成分の分散: $V[y_j] = \frac{1}{n-1} \|\mathbf{y}_j\|^2 = \frac{1}{n-1} \mathbf{y}_j^\top \mathbf{y}_j = \frac{1}{n-1} (\mathbf{X}_c \mathbf{u}_j)^\top (\mathbf{X}_c \mathbf{u}_j) = \mathbf{u}_j^\top \left(\frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \right) \mathbf{u}_j = \mathbf{u}_j^\top S \mathbf{u}_j = \mathbf{u}_j^\top (\lambda_j \mathbf{u}_j) = \lambda_j (\mathbf{u}_j^\top \mathbf{u}_j) = \lambda_j$ ($\times$ 異なる成分の共分散、相関は 0)
- 主成分負荷量 (元データと主成分の相関係数): $r_{y_j, x_k} = \frac{\text{Cov}[x_k, y_j]}{\sqrt{V[y_j] s_{k,k}}} = \frac{\sqrt{\lambda_j} u_{k,j}}{\sqrt{s_{k,k}}}$
- 特異値分解: $\mathbf{X}_c^\top = \sum_{j=1}^r \sqrt{\xi_j} \mathbf{u}_j \mathbf{v}_j^\top$, $\mathbf{v}_j = \frac{1}{\sqrt{\xi_j}} \mathbf{X}_c \mathbf{u}_j$
 - 特異値から固有値の算出: $\xi_j = (n-1)\lambda_j > 0$ ($\times$ 特異値を二乗して $n-1$ で割れば固有値となる)
- 自己符号化器: ニューラルネットワークの符号化、複合化の再構成誤差を小さくすることと主成分分析は同じ
 - 主成分分析は直線によって再構成誤差を小さく、ニューラルネットワークは活性化関数で再構成誤差を小さくしている

判別分析

- フィッシャーの判別分析
 - 基準 (最大にする): $\lambda(\mathbf{w}) = \frac{\text{群間分散}}{\text{群内分散}} = \frac{(\bar{y}^{(1)} - \bar{y}^{(2)})^2}{\mathbf{w}^\top \left[\frac{1}{n_1 + n_2 - 2} ((n_1 - 1)S_1 + (n_2 - 1)S_2) \right] \mathbf{w}} = \frac{(\mathbf{w}^\top (\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)}))^2}{\mathbf{w}^\top S \mathbf{w}}$
 - 射影方向: $\hat{\mathbf{w}} = S^{-1}(\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})$
 - フィッシャーの線形判別関数: $f(\mathbf{x}) = \hat{\mathbf{w}}^\top \mathbf{x} - \frac{1}{2} \hat{\mathbf{w}}^\top (\bar{\mathbf{x}}^{(1)} + \bar{\mathbf{x}}^{(2)}) = \hat{\mathbf{w}}^\top \mathbf{x} - \frac{1}{2} (\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})^\top S^{-1} (\bar{\mathbf{x}}^{(1)} + \bar{\mathbf{x}}^{(2)})$
 - 正なら群 G_1 、負なら群 G_2 に分類
 - 中点: $\frac{1}{2} (\hat{\mathbf{w}}^\top \bar{\mathbf{x}}^{(1)} + \hat{\mathbf{w}}^\top \bar{\mathbf{x}}^{(2)}) = \frac{1}{2} \hat{\mathbf{w}}^\top (\bar{\mathbf{x}}^{(1)} + \bar{\mathbf{x}}^{(2)})$
 - マハラノビス平方距離: $D^2 = (\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})^\top S^{-1} (\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})$
 - 判別対象のサンプルと群の平均ベクトルまでのマハラノビス平方距離に近い群へと分類
 - 生起確率が異なる場合の判別: $f(\mathbf{x}) - \log(\pi_2/\pi_1)$ で判別 ($\times \pi_1 = 1 - \pi_2$)
 - 個別の分散共分散行列を使う場合: $q(\mathbf{x}) = D_2^2 - D_1^2 = (\mathbf{x} - \bar{\mathbf{x}}^{(2)})^\top S_2^{-1} (\mathbf{x} - \bar{\mathbf{x}}^{(2)}) - (\mathbf{x} - \bar{\mathbf{x}}^{(1)})^\top S_1^{-1} (\mathbf{x} - \bar{\mathbf{x}}^{(1)})$
 - $q(\mathbf{x})$ を 2 次判別関数と呼び、当該関数を使う判別分析を 2 次判別分析と呼ぶ
- 正準判別分析
 - マハラノビス距離を求めて最も近いものに分類
 - 群間変動行列: $S_B = \sum_{j=1}^g n_j (\bar{\mathbf{x}}^{(j)} - \bar{\mathbf{x}}) (\bar{\mathbf{x}}^{(j)} - \bar{\mathbf{x}})^\top$
 - 群内変動行列: $S_W = \sum_{j=1}^g (n_j - 1) S_j$, $S_j = \frac{1}{n_j - 1} \sum_{i=1}^{n_j} (\bar{\mathbf{x}}_i^{(j)} - \bar{\mathbf{x}}^{(j)}) (\bar{\mathbf{x}}_i^{(j)} - \bar{\mathbf{x}}^{(j)})^\top$
 - ランクはたかだか $g - 1$ となる
 - 白色化 (スフエーリング) した場合はマハラノビス距離とユークリッド距離は一致する
- サポートベクターマシン

- 判別平面と最も近いデータ点の距離（マージン）を最大化
- サンプルと超平面の距離: $\frac{w^\top \phi(x_i) + b}{\|w\|}$
- 最適化問題への帰着: $\min_{w,b} \|w\|^2 \quad \text{s.t.} \quad y_i(w^\top \phi(x_i) + b) \geq 1, \quad \forall i$
- パラメータの線形結合化: $\min_{\alpha_1, \dots, \alpha_n, b} \sum_{i,j=1}^n \alpha_i \alpha_j \phi(x_i)^\top \phi(x_j) \quad (\ast k(x_i, x_j) = \phi(x_i)^\top \phi(x_j) \text{ はカーネル関数})$
 - ソフトマージン: 線形分離でなくても定義できる判別関数
 - 定式化: $\min_{\alpha, b, \xi} \alpha^\top K \alpha + C \sum_{i=1}^n \xi_i, \quad \text{s.t.} \quad \xi \geq 0, \xi \geq 1 - y_i (\sum_{j=1}^n \alpha_j K_{ji} + b)$
 - C はペナルティをコントロールするソフトマージンパラメータ

クラスター分析

- ミンコフスキー距離: $d_m(x, y) = (\sum_{i=1}^p |x_i - y_i|^m)^{\frac{1}{m}}$
 - $m = 1$ でマンハッタン距離、 $m = 2$ でユークリッド距離
- マハラノビス距離: $d_M(x, y) = \sqrt{(x - y)^\top \Sigma^{-1} (x - y)}$ ($\ast \Sigma$ は共分散行列)
 - 階層的クラスタリング: 1サンプル1クラスターの状態から樹状図（デンドログラム）を作るようにクラスター同士を統合していく
 - 最近隣法（単リンク法）: サンプル間の最短距離が最短のクラスター同士を合併する
 - 最遠隣法（最長距離法）: サンプル間の最長距離が最短のクラスター同士を合併する
 - 重心法（セントロイド法）: 重心が計算できる場合に重心距離が最短のクラスター同士を合併する
 - 群平均法: サンプル間の距離平均が最短のクラスター同士を合併する
 - ウォード法: 併合後の距離の二乗和と併合前の距離の二乗和の差が最小になるクラスター同士を合併する
 - 合併によるばらつきの増加が最も小さくなるように合併する
 - $d(C_1, C_2) = \sum_{z \in C_1 \cup C_2} d(z, \bar{z})^2 - d(x, \bar{x})^2 - d(y, \bar{y})^2, \quad \bar{z} = \frac{|C_1|}{|C_1| + |C_2|} \bar{x} + \frac{|C_2|}{|C_1| + |C_2|} \bar{y}$
- 非階層的クラスタリング:
 - K -means法: 「クラスター中心の更新」と「クラスター割当の更新」により予め決めたクラスター数 K に分類する
 - クラスター中心の更新: 現在のクラスターに割り当てられている対象の中心を計算
 - クラスター割当の更新: すべてのサンプルを中心との距離が最も近いクラスターに再割当

因子分析・グラフィカルモデル

- 1因子モデル: $x_{ij} = a_j f_i + d_j u_{ij} \quad (\ast f_1, \dots, f_n \sim N(0, 1), u_{ij} \sim N(0, 1), f_i \text{ と } u_{ij} \text{ は互いに独立})$
 - a_j は因子負荷量、 f_i は因子スコア（共通因子）、 $d_j > 0$ は独自係数（ $d_j u_{ij}$ の標準偏差）、 u_{ij} は独自性因子
 - $V[x_{ij}] = a_j^2 + d_j^2 = 1 \quad (\ast a_j^2 = 1 - d_j^2 \text{ は共通性、} d_j^2 \text{ は独自性、多因子モデルも同様})$

- **多因子モデル**: $x_{ij} = a_{j1}f_{i1} + \dots + a_{jL}f_{jL} + d_j u_{ij}$
 - **K因子モデル**: $X = FA^\top + UD = (FT)(T^{-1}A^\top) + UD$ (※ T は $TT^\top$ の対角成分がすべて1となる $K \times K$ の正則行列)
 - $X = x_{ij}, F = f_{jk}, A = a_{jk}, U = u_{ij}, D = \text{diag}(d_1, \dots, d_p)$
 - $\tilde{F} = FT, \tilde{A} = (T^{-1}A^\top)^\top = A(T^\top)^{-1}$
 - T を適用するのは軸を回転させるのと同義、回転により成分の解釈を補助する
 - T が直交行列の場合は直交回転となる ($f_{11}, \dots, f_{iK}$ が互いに独立な場合に用いる)
 - **バリマックス回転**: 因子負荷行列 A の各要素を2乗してできた行列の各列の分散を最大にする直交回転
 - **寄与率**: $\frac{1}{K}a_{jk}$ (※共通因子が全体のどれだけ説明できているかを示す)
- **構造方程式モデル**: 有向グラフ (すべての辺が矢印のグラフ) のモデル
 - X_1 と X_2 が矢印で接続されているとき $X_2 = aX_1 + u$ で表される (※ a はパス係数)
 - 両辺に X_1 を掛けて期待値を取ることで $a = \rho_{X_1X_2}$ となる (標本共分散)
- **グラフィカルモデル**: 無向グラフ (すべての辺が無向辺のグラフ) のモデル
 - 多変量正規分布の各分布を頂点に持ち、直接辺が繋がっていなければ条件付独立、辺が無く孤立していれば独立
 - **モラルグラフ**: 有向グラフの線に加えて、同一頂点に2頂点からの矢印がある場合は2頂点間に辺を加える

多変量解析

- **多次元尺度法**: n 個体の距離 (非類似度) の位置関係を低次元 (2~3) の座標で表現する手法
 - **二重中心化**: $B = XX^\top = -\frac{1}{2} \left(I_n - \frac{1}{n} J_n \right) D \left(I_n - \frac{1}{n} J_n \right)$
 - **エッカート・ヤング分解**: $B = U\Lambda U^\top \rightarrow X = U\Lambda^{\frac{1}{2}}$
 - 大きい方の固有値のみ採用して打ち切る (2つなら散布図に表現可能)
 - **正準相関分析**: 2つの変数群の線形結合が高い相関となるようにして、両変数群の関係を解釈する手法
 - 主成分分析の一般化
- **数量化法**
 - **説明変数・目的変数が連続データ**: 重回帰分析
 - **説明変数が質的データ**: 数量化Ⅰ類
 - **目的変数が質的データ**: 判別分析
 - **説明変数・目的変数が質的データ**: 数量化Ⅱ類
 - **質的データの関係 (主成分分析相当)**: 数量化Ⅲ類
 - **対応分析**: 分割表で表されるデータの分析

時系列解析

- **共分散定常過程 (弱定常過程)**: $E[Y_t] = \mu, \text{Cov}[Y_t, Y_{t-h}] = \gamma_{|h|} \quad (0 < V[Y_t] = \gamma_0 < \infty)$
 - 期待値分散が有限で平均も自己共分散も時間に依存しない

- 確率分布自体が時間に依存しない場合は強定常過程（ただし、期待値分散が有限である必要はない）
- **ホワイトノイズ**: 共分散定常過程で互いに独立で平均 0、 $h \neq 0$ のすべての自己共分散が 0
 - 互いに独立で平均 0、分散 1 の同一分布に従う場合はホワイトノイズ
 - 重回帰モデルの U_t もホワイトノイズで仮定されることが多い（平均 0、分散 σ^2 ）
- **自己回帰過程(AR過程)**:
 - **AR(1)過程**: $Y_t = \phi_1 Y_{t-1} + U_t = \phi_1^t Y_0 + \sum_{j=1}^t \phi_1^{t-j} U_j$ (U_t はショックと呼ぶ、ホワイトノイズが仮定される)
 - $|\phi_1| > 1$ で時間経過で影響大、 $|\phi_1| = 1$ で影響一定、 $|\phi_1| < 1$ で影響小（共分散定常）
 - 一般式: $Y_t = c + \phi_1 Y_{t-1} + U_t$
 - 期待値（共分散定常の場合）: $E[Y_t] = c + \phi_1 Y_{t-1} \iff \mu = \frac{c}{1-\phi_1}$
 - 分散（共分散定常の場合）: $V[Y_t] = \gamma_0 = \frac{\sigma^2}{1-\phi_1^2}$
 - 自己共分散（共分散定常の場合）: $\gamma_h = \phi_1^h \frac{\sigma^2}{1-\phi_1^2}$
 - 自己相関係数（共分散定常の場合）: $\rho_h = \phi_1^h$
 - **AR(p)過程**: $Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + U_t$
 - 期待値（共分散定常の場合）: $E[Y_t] = \frac{c}{1-\phi_1-\dots-\phi_p}$
- **移動平均過程(MA過程)**:
 - **MA(1)過程**: $Y_t = \mu + U_t + \theta_1 U_{t-1}$
 - 期待値: $E[Y_t] = \mu$
 - 自己共分散:
 - $h = 0$ の場合: $\gamma_0 = E[(U_t + \theta_1 U_{t-1})^2] = E[U_t^2 + \theta_1^2 U_{t-1}^2 + 2\theta_1 U_t U_{t-1}] = (1 + \theta_1^2) \sigma^2$
 - $h = 1$ の場合: $\gamma_1 = E[(U_t + \theta_1 U_{t-1})(U_{t-1} + \theta_1 U_{t-2})] = \theta_1 \sigma^2$
 - $h > 1$ の場合: $\gamma_h = E[(U_t + \theta_1 U_{t-1})(U_{t-h} + \theta_1 U_{t-h-1})] = 0$
 - **MA(q)過程**: $Y_t = \mu + U_t + \theta_1 U_{t-1} + \theta_2 U_{t-2} + \dots + \theta_q U_{t-q}$
 自己共分散:
 - $h = 0$ の場合: $\gamma_0 = (1 + \theta_1^2 + \dots + \theta_q^2) \sigma^2$
 - $1 \leq h \leq q$ の場合: $\gamma_h = (\theta_h + \theta_1 \theta_{h+1} + \dots + \theta_{q-h} \theta_q) \sigma^2$
 - $h > q$ の場合: $\gamma_h = E[(U_t + \theta_1 U_{t-1})(U_{t-h} + \theta_1 U_{t-h-1})] = 0$
- **自己回帰移動平均過程(ARMA(p,q)過程)**: $Y_t = c + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + U_t + \theta_1 U_{t-1} + \dots + \theta_q U_{t-q}$
- **自己回帰和分移動平均過程(ARIMA(p,1,q)過程)**: $\Delta Y_t = c + \phi_1 \Delta Y_{t-1} + \dots + \phi_p \Delta Y_{t-p} + U_t + \theta_1 U_{t-1} + \dots + \theta_q U_{t-q}$
 - **単位根検定**: 階差を取るかの仮説検定、 $\phi_1 = 1$ のt検定はディッキー・フラー検定（要特別な分布表）
- **ラグ多項式**: $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$
 - **ラグオペレーター**: $LY_t = Y_{t-1}$
 - **ALMA過程**: $\phi(L)Y_t = c + \theta(L)U_t$
- **次数の決定**:

自己相関係数	偏自己相関係数	選択モデル
2次以降0	ゆっくりと減衰	MA(1)
3次以降0	ゆっくりと減衰	MA(2)
ゆっくりと減衰	2次以降0	AR(1)
ゆっくりと減衰	3次以降0	AR(2)
ゆっくりと減衰	ゆっくりと減衰	ARMA(1,1)

- **スペクトラム**: $f(\lambda) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} \gamma_h e^{-i\lambda h} = \frac{1}{2\pi} (\gamma_0 + 2 \sum_{h=1}^{\infty} \gamma_h \cos(\lambda h))$
 - **ド・モアブルの定理**: $e^{-i\lambda h} = \cos(\lambda h) - i \sin(\lambda h)$
 - **ARMA(p,q)過程のスペクトラム**: $f(\lambda) = \frac{\sigma^2 |\theta(e^{i\lambda})|^2}{2\pi |\phi(e^{i\lambda})|^2} = \frac{\sigma^2}{2\pi} \frac{\theta(e^{-i\lambda})\theta(e^{i\lambda})}{\phi(e^{-i\lambda})\phi(e^{i\lambda})}$
 - **ホワイトノイズ**: $\cos$ 項は自己共分散 0 なので、 $f(\lambda) = \frac{1}{2\pi} \gamma_0 = \frac{\sigma^2}{2\pi}$
 - **AR(1)過程**: $\phi(L)Y_t = c + U_t$ より、 $f(\lambda) = \frac{\sigma^2}{2\pi} \frac{1}{\phi(e^{-i\lambda})\phi(e^{i\lambda})} = \frac{\sigma^2}{2\pi} \frac{1}{(1-\phi_1 e^{-i\lambda})(1-\phi_1 e^{i\lambda})} = \frac{\sigma^2}{2\pi} \frac{1}{1+\phi_1^2-2\phi_1 \cos(\lambda)}$
- **ペリオドグラム**: $\hat{f}(\lambda) = \frac{1}{2\pi} \sum_{h=-T+1}^{T-1} \hat{\gamma}_h e^{-i\lambda h}$
 - **波動関数への回帰**: $y_t = \hat{\mu} + \sum_{h=1}^M \left[\hat{\alpha}_h \cos(\lambda_h(t-1)) + \hat{\beta}_h \sin(\lambda_h(t-1)) \right]$
 - **分散の分解**: $\frac{1}{T} \sum_{t=1}^T (y_t - \bar{y})^2 = \frac{1}{2} \sum_{h=1}^M (\hat{\alpha}_h^2 + \hat{\beta}_h^2)$
 - **周期要因への分解**: $\frac{1}{2} (\hat{\alpha}_h^2 + \hat{\beta}_h^2) = \frac{4\pi}{T} \hat{f}(\lambda_h)$
- **状態空間モデル**:
 - **観測方程式**: $Y_t = \mathbf{X}_t^\top \boldsymbol{\beta}_t + U_t$ (※観測されない潜在変数 α などを加える場合もある)
 - **状態方程式 (遷移方程式)**: $\boldsymbol{\beta}_t = \Phi \boldsymbol{\beta}_{t-1} + \mathbf{V}_t$
- **ダービン・ワトソン検定**: 回帰モデルの誤差項 U_t がホワイトノイズでない (自己相関や系列相関がある) ことの仮説検定
 - **検定モデル**: $U_t = \rho U_{t-1} + \varepsilon_t$ (※AR(1)モデルを想定)
 - **検定量 (ダービン・ワトソン比)**: $DW = \frac{\sum_{t=2}^T (\hat{U}_t - \hat{U}_{t-1})^2}{\sum_{t=1}^T \hat{U}_t^2} = \frac{\sum_{t=2}^T \hat{U}_t^2 + \sum_{t=2}^T \hat{U}_{t-1}^2 - 2 \sum_{t=2}^T \hat{U}_t \hat{U}_{t-1}}{\sum_{t=1}^T \hat{U}_t^2} \approx 2 \left(1 - \frac{\sum_{t=2}^T \hat{U}_t \hat{U}_{t-1}}{\sum_{t=1}^T \hat{U}_t^2} \right) = 2(1 - \hat{\gamma}_1)$
 - 最小二乗法の残差で検定する
 - $\hat{\gamma}_1$ は1次の自己相関係数の推定量
 - $\rho > 0$ の検定:
 - $\rho = 0 \iff \hat{\gamma}_1 \approx 0 \iff DW \approx 2$
 - $\rho > 0 \iff \hat{\gamma}_1 > 0 \iff DW < 2$
 - DW比が2に近い場合は帰無仮説を受容、2より十分小さな場合は棄却
 - $\rho < 0$ の検定:
 - DW比が2より大きくなるので $4 - DW$ が2に近い場合は帰無仮説を受容、2より十分小さな場合は棄却

- 検定不能領域が存在することと、被説明変数の過去の値を説明変数として含むようなモデルでは使えない

分割表

- オッズ比: $\psi = \frac{\theta_1/(1-\theta_1)}{\theta_2/(1-\theta_2)}$
 - 対数オッズ比: $\log \psi$
 - 標本オッズ比: $OR = \frac{x_1(n_2-x_2)}{x_2(n_1-x_1)}$
 - 標本対数オッズ比の推定誤差: $\sqrt{V[\log OR]} = \sqrt{\frac{1}{x_1} + \frac{1}{n_1-x_1} + \frac{1}{x_2} + \frac{1}{n_2-x_2}}$
 - 前向き研究と後ろ向き研究の関係:
 - $\theta_1 = P(B_1|A_1) = \frac{P(A_1|B_1)P(B_1)}{P(A_1)} = \eta \times \frac{P(B_1)}{P(A_1)}$
 - $\theta_2 = P(B_1|A_2) = \frac{P(A_2|B_1)P(B_1)}{P(A_2)} = (1-\eta) \times \frac{P(B_1)}{P(A_2)}$
 - $\frac{\eta_1/(1-\eta_1)}{\eta_2/(1-\eta_2)} = \frac{P(A_1|B_1)/P(A_2|B_1)}{P(A_1|B_2)/P(A_2|B_2)} = \frac{P(B_1|A_1)/P(B_2|A_1)}{P(B_1|A_2)/P(B_2|A_2)} = \frac{\theta_1/(1-\theta_1)}{\theta_2/(1-\theta_2)} = \psi$
 - 相対リスク: $\psi = \frac{\theta_1/(1-\theta_1)}{\theta_2/(1-\theta_2)} \approx \theta_1/\theta_2$
- ピアソンカイ二乗検定: $\chi^2 = \sum_i \sum_j \frac{(x_{ij}-m_{ij})^2}{m_{ij}}$ (※自由度は1)
- 尤度比検定:
 - 対数尤度比: $\log \Lambda = \log \left(\frac{\prod_{i,j} (x_{ij})^{x_{ij}}}{\prod_{i,j} (m_{ij})^{x_{ij}}} \right) = \log \left\{ \prod_{i,j} \left(\frac{x_{ij}}{m_{ij}} \right)^{x_{ij}} \right\} = \sum_{i,j} x_{ij} \log \frac{x_{ij}}{m_{ij}}$
 - 逸脱度: $G^2 = 2 \log \Lambda = 2 \sum_{i,j} x_{ij} \log \frac{x_{ij}}{m_{ij}} \sim \chi^2$ (※自由度は1)
- フィッシャーの正確検定: 超幾何分布（非復元抽出）を考えたときの x_{11} の度数となるP値から検定する
 - $P(X_{11} = x_{11}) = \frac{x_{11} C_{x_{11}} \times x_{22} C_{x_{11}-x_{11}}}{x_{..} C_{x_1}} = \frac{x_{11}! x_{22}! x_{11}! x_{22}!}{x_{..}!} \frac{1}{x_{11}! x_{12}! x_{21}! x_{22}!}$
- その他の2×2分割表:
 - 多項分布: 全体nに対して2水準×2水準で集計した場合（総和のみ所与のため次元は3）
 - 確率関数: $P(X_{ij} = x_{ij}, i, j = 1, 2) = \frac{n!}{x_{11}! x_{12}! x_{21}! x_{22}!} \theta_{11}^{x_{11}} \theta_{12}^{x_{12}} \theta_{21}^{x_{21}} \theta_{22}^{x_{22}}$
 - 独立性の仮説: $H_0: \theta_{ij} = \theta_{i.} \theta_{.j}$ (※それぞれの因子が独立か)
 - オッズ比を導入してオッズ比が1かを検定することもできる
 - ポアソン分布: すべてが独立の2水準×2水準で集計した場合（総和も所与ではないため次元は4）
 - 確率関数: $P(X_{ij} = x_{ij}) = \prod_{i=1}^2 \prod_{j=1}^2 e^{-\theta_{ij}} \frac{\theta_{ij}^{x_{ij}}}{x_{ij}!}$
 - 飽和モデル（主効果モデル）: $\log \theta_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}$
 - μ : 全体のベース、 α_i : 要因A（行）の単独効果、 β_j : 要因B（列）の単独効果、 γ_{ij} : 要因AとBの相互作用
- 2元分割表（多水準）:

飽和モデル	自由度	帰無仮説	自由度	自由度の差
行ごとに独立な多項分布	$I(J-1)$	一様性の仮説	$J-1$	$(I-1)(J-1)$

飽和モデル	自由度	帰無仮説	自由度	自由度の差
全体が1つの多項分布	$IJ - 1$	独立性の仮説	$(I - 1) + (J - 1)$	$(I - 1)(J - 1)$
独立なポアソン分布	IJ	主効果モデル	$1 + (I - 1) + (J - 1)$	$(I - 1)(J - 1)$

• 3元分割表:

◦ 多項分布:

- 完全独立モデル: $\theta_{ijk} = \theta_{i..}\theta_{.j.}\theta_{..k}$, $\forall i, j, k \Rightarrow A \perp B \perp C$
 - 最尤推定量: $\hat{\theta}_{ijk} = \frac{x_{i..}x_{.j.}x_{..k}}{n^3}$
 - 当てはめ値: $m_{ijk} = \frac{x_{i..}x_{.j.}x_{..k}}{n^2}$
 - 対数線形モデル (階層モデル): $\log \theta_{ijk} = \mu + \alpha_i + \beta_j + \gamma_k$
- 周辺独立モデル: $\theta_{ijk} = \theta_{i..}\theta_{.jk}$, $\forall i, j, k \Rightarrow A \perp (B, C)$
 - 最尤推定量: $\hat{\theta}_{ijk} = \frac{x_{i..}x_{.jk}}{n^2}$
 - 当てはめ値: $m_{ijk} = \frac{x_{i..}x_{.jk}}{n}$
 - 対数線形モデル (階層モデル): $\log \theta_{ijk} = \mu + \alpha_i + \beta_j + \gamma_k + (\beta\gamma)_{jk}$
- 条件付き独立モデル: $\theta_{ijk} = \frac{\theta_{i.k}\theta_{.jk}}{\theta_{..k}}$, $\forall i, j, k \Rightarrow A \perp B \mid C$
 - 最尤推定量: $\hat{\theta}_{ijk} = \frac{x_{i.k}x_{.jk}}{nx_{..k}}$
 - 当てはめ値: $m_{ijk} = \frac{x_{i.k}x_{.jk}}{x_{..k}}$
 - 対数線形モデル (階層モデル): $\log \theta_{ijk} = \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk}$

• グラフィカルモデル:

- 部分グラフ: 元のグラフから一部分を切り出したグラフ
- 完全部分グラフ: 部分グラフのすべての頂点が互いに直接つながっているグラフ (2頂点のグラフ、三角形のグラフなど)
- クリーク: 極大の完全部分グラフ、つまり完全部分グラフに1頂点でも追加すると完全部分グラフではなくなるもの
- AB/BCD の対数線形モデル: $\log \theta_{ijkl} = \mu + \alpha_i + \beta_j + \gamma_k + \delta_l + (\alpha\beta)_{ij} + (\beta\gamma)_{jk} + (\beta\delta)_{jl} + (\gamma\delta)_{kl} + (\beta\gamma\delta)_{jkl}$
- 連結でない (他頂点を経由しても繋がっていない) 因子同士は独立
- 連結であるが直接の枝が存在しない因子同士は他すべての因子を固定した時に条件付き独立
- 連結であり頂点 S で分離される (特定の頂点を経由しないと繋がらない) 因子同士は S を固定した時に条件付き独立

不完全データの統計処理

- MCAR(Missing Completely At Random): 完全ランダムな欠測
 - 欠測による平均・標準偏差・相関係数・定数項・傾きへの影響は少ない
- MAR(Missing At Random): 観測データに依存 (例: 観測値 X が一定以上の場合に欠測) するが欠測データには依存しない

- 欠測範囲と欠測データの相関により平均と標準偏差が影響を受けるが、相関係数・定数項・傾きへの影響は少ない
- **MNAR(Missing Not At Random)**: 欠測データに依存（例：変数値 Y が一定以上の場合に欠測）する
 - 欠測データが欠けているので全体的に影響が出る（MARより影響が大きい）
- **削除法**:
 - **CC解析**: 欠測があるデータを個体単位で削除
 - 欠測値に傾向がある場合は影響が出る
 - **AC解析**: 欠測がある変数以外は削除しない（使えるものは使う）
 - CC解析より個体数が減りにくいが、変数ごとの個体数が変わるので分散共分散行列の計算（自由度など）に影響が出る
 - 欠測数が少ない場合はCC解析の方が妥当になりやすい
- **補完法**:
 - **平均値代入**: 欠測以外の平均値を代入
 - **回帰代入**: 回帰式から計算して代入
 - **Hot Deck法**: 欠測個体と類似個体を探して代入
- **対応の選択**:
 - **MCARの場合**: CC解析が妥当な結果となる
 - **MARの場合**: CC解析と平均値代入は偏りが出る、回帰代入は平均の偏りはでないが標準偏差と相関係数が偏る
 - 多重代入法を用いるのがよい
 - **MNARの場合**: 個別対応が必要
- **1変量正規分布**:
 - MCARの場合はCC分析でよいが、MNARの場合は考慮が必要
 - **打ち切り**: 一定以下（以上）のデータが観測できなかったが、観測できなかった個数は分かっている
 - **トランケート**: 観測できなかった個数も不明
 - **確率密度関数**:
$$f_c(x) = \begin{cases} \frac{1}{\Phi((c-\mu)/\sigma)} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) & (x \leq c) \\ 0 & (x > c) \end{cases}$$
 - **期待値**: $E[Z|Z \leq a = (c - \mu)/\sigma] = -\frac{\varphi(a)}{\Phi(a)}$
 - **分散**: $V[Z|Z \leq a = (c - \mu)/\sigma] = 1 - \frac{a\varphi(a)}{\Phi(a)} - \left(\frac{\varphi(a)}{\Phi(a)}\right)^2$
 - **打ち切りのEステップ**: $E[X|X > c] = \mu^{(t)} + \sigma^{(t)} \frac{\varphi(a)}{1-\Phi(a)}$
 - **打ち切りのMステップ**: $\mu^{(t+1)} = \frac{1}{n} (\sum_{i=1}^m x_i + (n - m)E[X|X > c])$
 - **トランケートの尤度関数**: $L(\mu, \sigma^2) = \prod_{i=1}^n f_c(x_i) = \prod_{i=1}^n \left[\frac{1}{\Phi((c-\mu)/\sigma)} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right) \right]$
 - **トランケートの期待値**: $\mu = \bar{x} + \frac{\varphi(a)}{\Phi(a)}\sigma$
 - **トランケートの期待値の漸化式**: $\mu^{(t+1)} = \bar{x} + \frac{\varphi(a^{(t)})}{\Phi(a^{(t)})}\sigma$ （※右辺にも μ を含むため漸化式を反復で解いて最尤推定値に近づける）
- **2変量正規分布**:
 - **同時確率密度関数**: $f(x, y) = f_1(x) \times f_2(y|x)$

- $f_1(x) = \frac{1}{\sqrt{2\pi}\sigma_X} \exp\left(-\frac{(x-\mu)^2}{2\sigma_X^2}\right)$
- $f_2(y|x) = \frac{1}{\sqrt{2\pi}\tau} \exp\left(-\frac{(y-(\alpha+\beta x))^2}{2\tau^2}\right)$
- **パラメータ**: $\alpha = \mu_Y - \beta\mu_X$, $\beta = \frac{\sigma_{XY}}{\sigma_X^2}$, $\tau^2 = \sigma_Y^2(1 - \rho^2) = \sigma_Y^2 - \frac{\sigma_{XY}^2}{\sigma_X^2}$
- **MARの最尤推定値**: $f_2(y|x)$ は平均が $\alpha + \beta x$ で分散が τ^2 の正規分布 $N(\alpha + \beta x, \tau^2)$ なのでこれを解く
 - **パラメータの式変形**: $\mu_Y = \alpha + \beta\mu_X$, $\sigma_Y^2 = \tau^2 + \beta^2\sigma_X^2$, $\sigma_{XY} = \beta\sigma_X^2$
 - **最尤推定値**: $\hat{\mu}_Y = \hat{\alpha} + \hat{\beta}\hat{\mu}_X$, $\hat{\sigma}_Y^2 = \hat{\tau}^2 + \hat{\beta}^2\hat{\sigma}_X^2$, $\hat{\sigma}_{XY} = \hat{\beta}\hat{\sigma}_X^2$, $\hat{\rho} = \frac{\hat{\sigma}_{XY}}{\hat{\sigma}_X\hat{\sigma}_Y}$
 - 回帰モデルのパラメータは欠損無しの組で産出、最尤推定値は欠損有りの組のデータも使用
- **EMアルゴリズム**: 対数尤度比の条件付き期待値を計算し、期待値を最大化して更新する
 - **Eステップ**: $q(\theta|\theta^*) = \int \log \frac{f(x,y;\theta)}{f(x,y;\theta^*)} f_{X|Y}(x|y;\theta^*) dx$
 - **Mステップ**: 最大化 (微分して 0 となる θ を新たな θ^* とする)

モデル選択

- **赤池情報量基準(AIC)**: $AIC = -2\log L + 2k$
 - **重回帰モデルのAIC**: $AIC(k) = n \left(\log S_e^{(k)} + \log \left(\frac{2\pi}{n} \right) + 1 \right) + 2(k+2)$
- **ベイズ情報量基準(BIC)**: $BIC = -2\log L + k \log n$
 - **重回帰モデルのBIC**: $BIC(k) = n \left(\log S_e^{(k)} + \log \left(\frac{2\pi}{n} \right) + 1 \right) + (k+2) \log n$
 - 標本が大きくなると真のモデルが選択されることが分かっている (偏回帰係数の真の値が0でない説明変数のみ取り込まれる)
- **クロスバリデーション (交差検証法)**:
 - データを K 分割、 $K-1$ セットのデータで判別関数を求め残り1セットで検証、これを K 通り行う
 - **Leave-one-out法**: $K = n$ としたクロスバリデーション
- **過学習**: パラメータを増やしすぎた結果、学習データへの判別率が良くなる一方で将来のデータの判別率が悪くなること

ベイズ法

- **ベイズの定理**: $\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{\int_{\Theta} f(x|\theta)\pi(\theta)d\theta} \propto f(x|\theta)\pi(\theta)$
- **ベイズ推定量**: $\hat{\theta}_B = \int_{\theta \in \Theta} \theta \cdot \pi(\theta|x) d\theta$ (※ θ の事後分布に対する期待値)
 - **ベイズリスク**: $\int_{\theta \in \Theta} (\hat{\theta} - \theta)^2 \pi(\theta|x) d\theta$ を最小にする推定量がベイズ推定量
- **MAP推定量**: $\hat{\theta}_{MAP} = \arg \max \pi(\theta|x) = \arg \max \{\log f(x|\theta) + \log \pi(\theta)\}$
 - 対数尤度関数 (最尤推定) に正則化項を持っている
- **ベータ・二項モデル**: α に成功回数 x を足し、 β に失敗回数 $n-x$ を足す
 - **尤度関数**: $f(x|p) = \binom{n}{x} p^x (1-p)^{n-x} \sim \text{Bin}(n, p)$

- 事前分布: $\pi(p) \propto p^{\alpha-1}(1-p)^{\beta-1} \sim Be(\alpha, \beta)$
- 事後分布: $\pi(p|x) \propto p^{\alpha+x-1}(1-p)^{\beta+n-x-1} \sim Be(\alpha+x, \beta+n-x)$
- 期待値: $\frac{\alpha}{\alpha+\beta}$
- モード: $\frac{\alpha-1}{\alpha+\beta-2}$
- **ガンマ・ポアソンモデル**: α に観測データの合計値 $\sum x_i$ を足し、 β に観測データ数 n を足す
 - 尤度関数: $f(x|\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \propto \lambda^{\sum x_i} e^{-n\lambda} \sim Po(\lambda)$
 - 事前分布: $\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda} \sim Ga(\alpha, \frac{1}{\beta})$
 - 事後分布: $\pi(\lambda|x) \propto \lambda^{\alpha+\sum x_i-1} e^{-(\beta+n)\lambda} \sim Ga(\alpha + \sum x_i, \frac{1}{\beta+n})$
 - 期待値: $\frac{\alpha}{\beta}$
 - モード: $\frac{\alpha-1}{\beta}$
- **正規・正規モデル**: 事後分布の平均は、事前平均と標本平均の「精度（分散の逆数）による加重平均」
 - 尤度関数: $f(x|\mu) \propto \exp\left(-\frac{n(\bar{x}-\mu)^2}{2\sigma^2}\right) \sim N(\mu, \sigma^2)$
 - 事前分布: $\pi(\mu) \propto \exp\left(-\frac{(\mu-\mu_0)^2}{2\sigma_0^2}\right) \sim N(\mu_0, \sigma_0^2)$
 - 事後分布: $\pi(\mu|x) \propto \exp\left(-\frac{(\mu-\mu_n)^2}{2\sigma_n^2}\right) \sim N(\mu_n, \sigma_n^2)$
 - 期待値: $\mu_n = \mu_n = \frac{\tau_0\mu_0 + n\tau\bar{x}}{\tau_0 + n\tau} = \frac{\frac{1}{\sigma_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}}$
 - 精度（分散の逆数）: $\tau_n = \tau_0 + n\tau = \frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}$
- **ベイズ予測**: $f(x_{n+1}|x) = \int_{\Theta} f(x_{n+1}|x, \theta) \pi(\theta|x) d\theta$
 - 事後分布の期待値（全確率の定理であらゆる θ の可能性を網羅して足し合わせている）
- **MHアルゴリズム**: 事後分布に従う乱数を観測して経験分布から事後分布を考察する方法
- **マルコフ連鎖モンテカルロ法（MCMC法）**: 事後分布に収束するように『提案と採択のルール（マルコフ連鎖）』を設計して動かす
 - Step0: 初期値 $\theta^{(0)}$ を設定
 - Step1: $q(\theta^{(t+1)}|\theta^{(t)})$ から移動先候補の発生（マルコフ連鎖）
 - Step2: 0から1の乱数 u が $\alpha(\theta^{(t)}, \theta^{(t+1)}) = \min\left\{1, \frac{\pi(\theta^{(t+1)}|x) q(\theta^{(t)}|\theta^{(t+1)})}{\pi(\theta^{(t)}|x) q(\theta^{(t+1)}|\theta^{(t)})}\right\}$ 以下なら採択
 - 以降指定回数まで繰り返す、ただし稼働検査期間のデータは除外する
 - 酔歩連鎖: $\alpha(\theta^{(t)}, \theta^{(t+1)}) = \min\left\{1, \frac{\pi(\theta^{(t+1)}|x)}{\pi(\theta^{(t)}|x)}\right\}$ （※進む確率と戻る確率が一緒の場合）
- **ギブス・サンプリング**: 1つを除いた全変数を固定した時の条件付き確率で動かす
 - Step0: 初期値 $\theta^{(0)}$ を設定
 - Step1: 1つを除いた全変数を固定した時の条件付き確率から全変数通り分生成して、それぞれ更新する
 - 既に更新済みの変数は更新後の変数で計算する
 - 以降指定回数まで繰り返す、ただし稼働検査期間のデータは除外する

シミュレーション

- **モンテカルロ法**: 乱数を観測することで近似値を求める方法
- **逆関数法**: 逆関数を求めて、逆関数に従う乱数を代入して元の関数の乱数とすること

- 採択棄却法: $f(x) = c^{-1}l(x)$ を覆う $Mg(x) \geq l(x)$ を用意して採択・棄却を繰り返す方法
 - x の採択率: $r = \frac{l(x)}{Mg(x)}$
 - 条件付き採択率: $P(I = 1, X = x) = g(x) \times \frac{l(x)}{Mg(x)} = \frac{l(x)}{M}$
 - 全採択率: $P(I = 1) = \int \frac{l(x)}{M} dx = \frac{1}{M} \int l(x) dx = \frac{c}{M}$
 - 採択されたうち x である確率: $p(x | I = 1) = \frac{l(x)/M}{c/M} = \frac{l(x)}{c} = f(x)$ (※元の確率であることが証明された)
- モンテカルロ積分: $E[g(X)] = \int_A g(x)f(x)dx = \theta$
 - 標本平均 $\hat{\theta} = \bar{g} = \frac{1}{m} \sum_{i=1}^m g(X_i)$ が θ に収束するので標本平均から θ を推測する
 - 分散: $\hat{\sigma}^2 = \frac{1}{m} \sum_{i=1}^m (g(X_i) - \hat{\theta})^2 \Rightarrow V[\hat{\theta}] = \sigma^2/m = \frac{1}{m^2} \sum_{i=1}^m (g(X_i) - \hat{\theta})^2$
 - 標準誤差 $se(\hat{\theta}) = \frac{1}{m} \left(\sum_{i=1}^m (g(X_i) - \hat{\theta})^2 \right)^{\frac{1}{2}}$
 - $(\hat{\theta} - \theta)/se(\hat{\theta}) \sim N(0, 1)$ から信頼区間を求められる
- モンテカルロ法の精度向上:
 - 主部の分離: e^x を $e^x - x - 1$ と $x + 1$ に分割して、 $e^x - x - 1$ にモンテカルロ法を適用する
 - 負の相関を利用: e^x を e^x と e^{1-x} の平均として、それぞれが強い負の相関を持つことを利用して分散を低減する
 - 相関係数: $\rho = \frac{\text{共分散}}{\text{分散}}$ (※ e^x と e^{1-x} の分散は同じなため)
- ジャックナイフ法: 1つだけデータを抜いたグループを全パターン作り、推定値のばらつきから標準誤差を推定
 - 1つ抜いたデータから推定値を計算: $\mathbf{x}_{(-j)} = (x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_n) \Rightarrow \hat{\theta}_{(j)} = T_{n-1}(\mathbf{x}_{(-j)})$
 - 推定値の平均: $\bar{\theta}_{(\cdot)} = \frac{1}{n} \sum_{j=1}^n \hat{\theta}_{(j)}$
 - 標準誤差のジャックナイフ推定量: $\widehat{se}_{\text{jack}} = \sqrt{\frac{n-1}{n} \sum_{j=1}^n (\hat{\theta}_{(j)} - \bar{\theta}_{(\cdot)})^2}$
- ブートストラップ法: 手元のデータから復元抽出で同サイズの標本を何回も擬似的に作り、推定値の分布や精度を評価
 - ブートストラップ標本: $\mathbf{x}^{*(b)} = (x_1^{*(b)}, \dots, x_n^{*(b)})$ (※元の標本から確率 $1/n$ でランダムに n 個のデータを抽出)
 - これを B 回繰り返す (50~200回程度)
 - 各標本の推定値: $\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^*(b) = \frac{1}{B} \sum_{b=1}^B T_n(\mathbf{x}^{*(b)})$
 - 標準誤差のブートストラップ推定量 $\widehat{se}_B = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^*(b) - \bar{\theta}^*)^2}$
 - バイアスの推定量: $\text{bias} = \bar{\theta}^* - \hat{\theta}$